

Analyse de l'évolution du profil sociodémographique des étudiants Data



Joana D'Arc Soares Aubry
Rôle: Data Analyst Junior - mai 2026

Objectif de la mission

Comprendre l'évolution du profil sociodémographique des étudiants Data sur 4 ans afin d'alimenter les réflexions sur l'accessibilité et l'égalité des chances.

Âge

Identifier la structure d'âge et son évolution

Genre

Suivre la part femmes/hommes et la qualité des données

Région

Observer les concentrations territoriales

INSEE

Contextualiser le profil OC avec la population française

Message clé

La restitution doit être claire pour un public non technique : les transformations sont réalisées en amont dans DBT/Snowflake, puis les indicateurs sont présentés dans Power BI et synthétisés dans le support.

Données utilisées et périmètre

Données internes OpenClassrooms

- Période : 2022–2025
- Dimensions : année, genre, tranche d'âge, région
- Indicateur : nombre d'étudiants
- Modalité conservée : Non renseigné


Usage : analyse interne OC

Données publiques INSEE

- Référentiel externe : 2025
- Population par région, genre, tranche d'âge
- Transformation département → région via COG
- Comparaison 2025 sur périmètre harmonisé

Usage : contextualisation OC vs INSEE

Pipeline DBT et Snowflake



Message clé

La séparation en couches rend le pipeline lisible et reproductible : chaque étape a un rôle précis, depuis les données brutes jusqu'au mart final consolidé utilisé dans Power BI.

Choix méthodologiques et RGPD

INSEE 2025

Référentiel externe stable pour contextualiser les données OC.

Non renseigné

Conservé dans l'analyse interne.
Comparaisons INSEE 2025 réalisées uniquement sur les genres comparables : femme et homme.

Tranches d'âge

Harmonisées sur le périmètre 20 ans et plus : exclusion des 0-19 ans, puis regroupement en 20-39, 40-59 et 60 ans ou plus.

RGPD

Restitution uniquement agrégée, sans identifiant individuel.

Décision clé


Les comparaisons INSEE sont construites sur des catégories communes et interprétées comme une contextualisation, pas comme une équivalence stricte.

Fiabilisation des données : contrôles clés

Contrôle	Résultat / usage
Volumes annuels	2022 = 1 696 ; 2023 = 1 150 ; 2024 = 850 ; 2025 = 951
Total général	4 647 étudiants validés
Genre	Non renseigné suivi en analyse interne ; exclu des comparaisons INSEE
Parts	Recomposition à 100 % par année et par périmètre d'analyse

Les contrôles Snowflake confirment la cohérence entre les marts DBT, les exports CSV et les visuels Power BI.


Évolution du nombre d'étudiants Data



Message clé

Le volume diminue entre 2022 et 2024, puis remonte légèrement en 2025. Cette dynamique sert de point de départ pour analyser l'évolution du profil sociodémographique.


Évolution de la répartition par genre



Message clé

La part des femmes augmente sur la période, passant de 17,8 % en 2022 à 30,7 % en 2025. La forte baisse du “Non renseigné” suggère une amélioration de la qualité de collecte, particulièrement visible en 2025.

Évolution par tranche d'âge



Points à faire ressortir


- La tranche 20–39 ans reste dominante.
- Les 40–59 ans sont moins représentés.
- Les 60+ sont marginaux dans la base OC.

Les tranches d'âge sont harmonisées sur le périmètre 20 ans et plus : 20–39, 40–59 et 60+.

La tranche 20–39 ans domine nettement sur toute la période.

Répartition régionale des étudiants OC

Répartition des étudiants Data par région (2025)



Message clé

En 2025, l'Île-de-France concentre 391 étudiants, soit un niveau très supérieur aux autres régions. Cette concentration invite à questionner l'accessibilité territoriale des parcours Data.

Comparaisons avec l'INSEE : méthode de lecture

Pour chaque dimension, les volumes OC et INSEE sont recalculés en parts sur le périmètre 2025 harmonisé.

Genre

femme / homme

Comparaison sur les genres
renseignés

Non renseigné exclu du benchmark
INSEE

Âge

20-39 • 40-59 • 60+

20 ans et plus ; 60-74 et 75+
regroupés en 60+


Région

part régionale

Parts recalculées à partir des
volumes harmonisés

Lecture : comparaison des parts OC vs INSEE pour identifier les sur- ou sous-représentations, sans interpréter les écarts comme une causalité.



Répartition par genre : OpenClassrooms vs INSEE



Message clé

En 2025, les hommes sont surreprésentés chez OpenClassrooms (67,2 % contre 47,7 % dans l'INSEE), tandis que les femmes restent sous-représentées. Ce constat alimente les réflexions sur l'égalité d'accès aux parcours Data.


Répartition par tranche d'âge et genre



Message clé

Le profil d'âge OC est nettement plus jeune que l'INSEE : les 20-39 ans sont surreprésentés chez les femmes comme chez les hommes, avec une concentration particulièrement marquée chez les hommes. Les 60+ restent très peu représentés.

Répartition régionale par genre : OpenClassrooms vs INSEE



Message clé

La concentration francilienne se confirme chez les femmes comme chez les hommes, avec un écart plus marqué chez les hommes. Ce constat invite à interroger l'accessibilité territoriale des parcours Data dans les régions moins représentées.

Enseignements clés et recommandations

Diversité de genre

Suivre la progression de la part des femmes et renforcer les actions d'orientation vers les parcours Data.

Accessibilité territoriale

Approfondir la concentration en Île-de-France et cibler les régions sous-représentées.

Profil d'âge

Adapter l'accompagnement à un public majoritairement 20–39 ans, souvent en reconversion.

Qualité des données

Continuer à réduire les valeurs “Non renseigné” pour fiabiliser les analyses futures.

Mieux connaître les profils étudiants permet de mieux cibler les actions en faveur de l'accessibilité et de l'égalité des chances.