

PROJET 13 • MISSION 1

Documentation de la démarche

Amélioration du livrable BottleNeck grâce à l'IA

Veille • cahier des charges • POC • pilotage • mini-formation

Joana Aubry

Parcours Data Analyst • OpenClassrooms

Version 1.1 • 09 août 2026

STATUT DU DOCUMENT

Version actualisée après retour mentor. La régression linéaire a été ajoutée à la comparaison prédictive, l'influence des variables du modèle de Poisson a été explicitée et les clusters ont été croisés avec les catégories de produits. La Mission 1 et le portfolio professionnel sont finalisés ; la préparation de la soutenance reste à consolider.

Pilotage du document

Ce dossier unique rassemble les preuves demandées pour la mission 1. Il évite la dispersion des livrables et permet de suivre, dans une même trame, les choix, essais, limites, décisions et éléments de conformité.

Informations générales

Élément	Contenu
Projet	Projet 13 – Pilotez un projet data augmenté avec l'IA
Cas d'étude	BottleNeck – rapprochement et analyse des données ERP/Web
Livrable amélioré	Notebook Python P13_BottleNeck_ameliore.ipynb
Période des données	Extraction au 31 octobre ; ventes du 1er au 31 octobre
Version du dossier	1.1 – actualisation après retour mentor du 9 août 2026

Sommaire de travail

N°	Section	Statut
1	Cadre de mission et besoin métier	Réalisé
2	Veille métier et technologique	Réalisé
3	Cahier des charges fonctionnel	Réalisé
4	Pilotage du projet data	Réalisé
5	Démarche IA et POC documenté	Réalisé
6	Mini-formation à destination des métiers	Réalisé
7	Reproductibilité, sécurité, conformité et sobriété	Réalisé
8	Synthèse recruteur/client	Réalisé
Annexes	Sources, prompts, résultats détaillés et grille qualité	Réalisé

État d'avancement des livrables

Livrable	Statut	Preuve actuelle
1. Notebook amélioré	Réalisé	Exécution complète sans erreur ni avertissement ; contrôles d'export conformes.
2. Documentation de la démarche	Réalisé	Ce document constitue la trame centrale et rassemble déjà les preuves disponibles.
3. Portfolio professionnel	Réalisé	Portfolio publié, projets hiérarchisés et veille professionnelle intégrée.

1. Cadre de mission et besoin métier

1.1 Contexte

BottleNeck est un marchand de vins dont les outils d'analyse restent artisanaux. Les informations produits, les stocks, les prix et les ventes proviennent de trois exports distincts : l'ERP, le site Web WordPress et une table de liaison. Les références n'étant pas homogènes entre les systèmes, leur rapprochement est une condition préalable à toute analyse fiable destinée au comité de direction.

1.2 Parties prenantes et décisions attendues

Partie prenante	Rôle	Décision / usage
Nicolas – responsable vente	Pilote métier	Valider les anomalies, prioriser les actions commerciales et le réapprovisionnement.
Comité de direction	Décideur	Arbitrer à partir du chiffre d'affaires, des marges, des stocks et des risques.
Équipes commerciales / stocks	Utilisateurs	Corriger les référentiels, suivre les ruptures et le capital immobilisé.
Data Analyst	Producteur et conseil	Fiabiliser, documenter, expliquer les limites et formuler des recommandations.

1.3 Reformulation du besoin métier

BESOIN REFORMULÉ

Construire une base analytique fiable en rapprochant les données ERP et Web, identifier et prioriser les anomalies, puis fournir au CODIR des indicateurs explicables sur le chiffre d'affaires, les marges, les ventes, les stocks, les ruptures et les risques d'immobilisation financière.

1.4 Priorités

Priorité	Enjeu	Exemples
Haute	Sécuriser les indicateurs et le rapprochement	Prix, ventes ou stocks négatifs ; SKU manquant ; produit actif sans liaison.
Moyenne	Maintenir les référentiels	Référence potentiellement obsolète ; incohérence de statut ou de liaison.
Faible	Améliorer progressivement la complétude	Catégorie non renseignée ; lignes techniques d'export.

1.5 Résultats consolidés du notebook amélioré

Indicateur	Résultat
Base analytique	714 produits · 36 colonnes · aucun product_id manquant ou dupliqué
Activité d'octobre	5 751 unités · CA TTC 143 680,10 € · CA HT estimé 119 733,42 €
Rentabilité	Marge brute 44 660,65 € · taux de marque 37,30 % · taux de marge 59,49 %
Stocks	Valeur ERP 298 627,66 € · DOH financier 119,34 jours · couverture physique médiane 2,40 mois
Risques	27 produits à risque d'immobilisation · 22 produits vendus mais en rupture
Qualité	41 anomalies consignées : 18 hautes, 21 moyennes et 2 faibles
POC prédictif	Quatre modèles comparés sur 714 produits. Régression de Poisson sans stock retenue : MAE de 2,46 unités, RMSE moyen de 3,31 et R^2 de 0,36. Régression linéaire conservée comme comparaison pédagogique ; POC non retenu pour un usage opérationnel.
Validation automatisée	POC Pandera conforme sur 714 lignes et huit colonnes ; six cas de non-conformité détectés sur la copie de test.

POINT DE VIGILANCE

Les données couvrent un seul mois. Les corrélations, couvertures de stock et recommandations décrivent la situation observée ; elles ne démontrent ni causalité ni tendance durable.

1.6 Principales améliorations par rapport au P6

Dimension	P6	Version améliorée
Structure	Cellules nombreuses et répétitives	Notebook resserré, sections narratives et sorties orientées décision.
Qualité	Contrôles dispersés	Journal global de 41 anomalies avec priorités, décisions et actions.
Méthodes	Une seule méthode par analyse	Comparaisons IQR/Z-score, Pearson/Spearman et de quatre modèles prédictifs ; analyse de l'influence des variables du Poisson ; POC Pandera exécuté.
Métier	Résultats techniques	Marges, mix, ruptures, couverture physique, DOH financier et priorités d'action.
Fiabilité	Vérifications partielles	Exports relus, modèle rechargé et quatorze contrôles finaux conformes après Run All.

2. Veille métier et technologique

2.1 Besoin de veille

QUESTION DE VEILLE

Comment fiabiliser et automatiser les contrôles qualité d'un rapprochement ERP-Web de faible volumétrie, tout en garantissant explicabilité, sécurité, maintenabilité et sobriété ?

Le notebook initial reposait sur des contrôles ponctuels et dispersés. La veille vise à identifier des méthodes statistiques, des outils de qualité et des approches prédictives proportionnés au contexte : faible volumétrie, exécution locale, besoin d'explication au CODIR et historique limité. L'absence de données sur plusieurs mois empêche une prévision opérationnelle fiable, mais permet de réaliser un POC exploratoire afin d'en mesurer la faisabilité et les limites.

2.2 Objectifs

- Renforcer la qualité du nettoyage et la traçabilité des anomalies.
- Comparer des méthodes statistiques adaptées à des distributions asymétriques et à des valeurs extrêmes.
- Évaluer l'intérêt d'un contrat de données automatisé sans surdimensionner la solution.
- Encadrer l'usage de l'IA : gains de temps, contrôles humains, sécurité et reproductibilité.
- Mettre en place un dispositif de veille maintenable comprenant un élément d'automatisation.
- Évaluer la faisabilité d'un modèle prédictif simple, comparer plusieurs algorithmes et identifier les risques de biais et de fuite de données.

2.3 Périmètre de la veille

La veille se concentre sur les solutions susceptibles d'améliorer la qualité, la traçabilité et la reproductibilité du rapprochement entre les données ERP et Web de BottleNeck.

Périmètre	Contenu
Inclus	IQR et Z-score ; Pearson et Spearman ; comparaison de modèles prédictifs ; segmentation non supervisée par K-means ; contrôles Pandas ; POC Pandera ; Great Expectations étudié ; assistant IA ; Feedly/RSS.
Exclus	Industrialisation des modèles, prévision opérationnelle des ruptures, causalité, architecture Big Data, déploiement cloud et données clients ou personnelles.
Critères	Qualité, robustesse/biais, temps, reproductibilité, sécurité/conformité, maintenabilité et sobriété.

Un POC prédictif exploratoire est inclus afin de comparer des approches adaptées à une cible de comptage. En revanche, la prévision opérationnelle et l'industrialisation restent hors périmètre en raison de l'absence d'historique sur plusieurs mois. Le scénario utilisant le stock de fin de mois est traité comme une analyse de sensibilité et écarté de la décision principale en raison du risque de fuite temporelle.

2.4 Protocole de veille

Étape	Règle appliquée
Automatiser	Centraliser automatiquement les nouvelles publications au moyen de quatre flux RSS officiels dans le dossier Feedly « Data Quality & IA ».
Collecter	Consulter la documentation officielle, les références méthodologiques, les notes de version et les retours d'expérience reconnus.
Qualifier	Vérifier l'auteur, la date, la finalité, les prérequis et l'applicabilité au cas BottleNeck.
Comparer	Appliquer une grille commune de critères et tester les options pertinentes sur les mêmes données.
Décider	Conserver, écarter ou différer chaque option avec une justification explicite.
Capitaliser	Enregistrer les sources, résultats, décisions, limites et pistes d'amélioration dans un journal de veille et dans la documentation du projet.
Restituer	Produire une synthèse mensuelle courte et intégrer les conclusions pertinentes au notebook, à la documentation et au portfolio.
Réviser	Réévaluer trimestriellement la pertinence des sources, des thèmes suivis et de la fréquence de consultation.

La collecte automatisée est consultée chaque semaine pendant environ vingt à trente minutes. Une capture du dossier Feedly et un extrait du journal de veille sont conservés comme preuves du fonctionnement du dispositif.

2.5 Comparaison des méthodes statistiques

Quatre expérimentations complémentaires ont été conduites sur les mêmes données : détection des prix atypiques, analyse des corrélations, comparaison d'approches prédictives et segmentation non supervisée des profils de stock.

2.5.1 Détection des prix atypiques

Critère de comparaison	Option A	Option B	Décision
Détection des prix atypiques	IQR ($1,5 \times$ écart interquartile)	Z-score (seuil 3)	IQR retenu comme méthode principale ; Z-score conservé comme contrôle complémentaire.
Résultat observé	31 prix signalés	13 prix signalés	Les 13 valeurs du Z-score appartiennent également au groupe IQR.
Robustesse / biais	Robuste aux valeurs extrêmes ; risque de signaler des produits premium légitimes.	Moyenne et écart-type influencés par les prix élevés ; risque de sous-détection.	Validation métier indispensable : une valeur atypique n'est pas automatiquement une erreur.
Coût / reproductibilité	Calcul local, déterministe et négligeable.	Calcul local, déterministe et négligeable.	Équivalents sur sécurité, conformité et sobriété.

2.5.2 Analyse des corrélations

Critère	Pearson	Spearman	Décision
Principe	Mesure l'intensité d'une relation linéaire entre les valeurs.	Mesure une relation monotone à partir du rang des observations.	Les deux méthodes sont comparées afin d'identifier l'influence de la distribution et des valeurs extrêmes.
Résultat observé	Relations plus faibles pour le stock et les ventes : stock-ventes = 0,44 ; prix-ventes = -0,52.	Relations plus marquées : stock-ventes = 0,76 ; prix-ventes = -0,70.	Spearman est retenu comme méthode principale d'interprétation ; Pearson reste un contrôle complémentaire.
Robustesse / biais	Sensible aux valeurs extrêmes et principalement adapté aux relations linéaires.	Moins sensible aux valeurs extrêmes, mais ne démontre pas une relation causale.	Les résultats sont interprétés comme des associations et non comme des causalités.
Coût / reproductibilité	Calcul local, déterministe et négligeable sur 713 observations communes.	Calcul local, déterministe et négligeable sur 713 observations communes.	Méthodes équivalentes en matière de sécurité, conformité, maintenabilité et sobriété.

2.5.3 Comparaison des approches prédictives

Un POC exploratoire a été réalisé afin d'évaluer la possibilité de prédire le volume mensuel des ventes par produit. Quatre modèles — référence naïve, régression linéaire, régression de Poisson et forêt aléatoire — ont été comparés sur les mêmes 714 observations au moyen d'une validation croisée à cinq partitions et d'un prétraitement commun.

Option	Justification	Résultat sans stock	Décision
Référence naïve	Prédit la moyenne et fournit un niveau minimal de comparaison.	MAE : 3,26 ; RMSE : 4,15 ; R^2 : -0,01.	Conservée uniquement comme référence.
Régression linéaire	Modèle additif simple et interprétable, mais non contraint à des valeurs positives.	MAE : 2,74 ; RMSE : 4,09 ; R^2 : -0,08 ; 10 prédictions négatives.	Comparaison pédagogique ; non retenue.
Régression de Poisson	Adaptée à une cible de comptage non négative et interprétable.	MAE : 2,46 ; RMSE : 3,31 ; R^2 : 0,36.	Retenue pour le POC.
Forêt aléatoire	Capte des relations non linéaires, mais offre une interprétation plus limitée.	MAE : 2,52 ; RMSE : 3,46 ; R^2 : 0,29.	Non retenue dans le scénario principal.

Un second scénario incluant le stock disponible au 31 octobre a amélioré artificiellement les performances de la forêt aléatoire, avec un MAE de 1,45 et un R^2 de 0,70. Ce résultat a été écarté, car le stock de fin de mois n'aurait pas été disponible au moment d'une prévision réalisée avant les ventes d'octobre : son utilisation introduirait une fuite temporelle.

Les quatre modèles présentent un coût de calcul faible et sont exécutés localement. La régression de Poisson est retenue pour sa meilleure performance sans stock, sa cohérence avec une cible de comptage, sa reproductibilité et sa maintenabilité. Elle reste toutefois limitée par un seul mois de données, la surestimation des ventes nulles et la sous-estimation des fortes ventes ; le modèle constitue une preuve de faisabilité et non un outil opérationnel.

Le retour mentor a conduit à approfondir l'interprétabilité du POC. La régression linéaire produit, sans stock, dix prédictions négatives et reste instable entre les partitions. Pour le Poisson final, une hausse d'un écart-type du prix de vente est associée à une diminution de 17,6 % des ventes estimées et une hausse d'un écart-type du prix d'achat à une diminution de 15,0 %, toutes choses égales par ailleurs. Les effets des catégories sont plus faibles ; ces associations ne démontrent pas une causalité.

2.5.4 Segmentation non supervisée des profils de stock

Un POC de clustering K-means a été réalisé sur 713 produits à partir des quantités vendues, du stock disponible et de sa valeur au prix d'achat. Plusieurs nombres de clusters ont été comparés à partir de l'inertie, du coefficient de silhouette et de leur utilité métier.

Critère	Solution à 2 clusters	Solution à 5 clusters	Décision
Séparation statistique	Meilleur coefficient de silhouette : 0,697.	Coefficient inférieur mais satisfaisant : 0,541.	Avantage statistique à la solution à deux clusters.
Niveau de détail	Deux groupes de 658 et 55 produits, séparant principalement les produits avec stock des produits à stock faible ou nul.	Cinq profils différenciant rotation soutenue, stock nul, ruptures actives, rotation faible et surstock.	La solution à cinq clusters apporte une lecture métier plus précise.
Résultat observé	Les ruptures et les stocks nuls restent regroupés dans un même ensemble.	Un cluster isole 20 des 22 ruptures actives ; un autre concentre 24 des 27 risques d'immobilisation.	Avantage opérationnel à la solution à cinq clusters.
Interprétabilité	Segmentation simple mais trop générale pour définir des actions ciblées.	Profils interprétables après croisement avec les segments métier.	Cinq clusters retenus pour l'analyse.
Robustesse / biais	Moins de groupes, mais risque de masquer les différences internes.	Segmentation plus détaillée, mais dépendante des variables, de leur transformation et de la période observée.	Validation sur plusieurs mois nécessaire.
Temps / reproductibilité	Calcul négligeable et reproductible.	Calcul négligeable avec n_init=20 et random_state=42 .	Solutions équivalentes en matière de coût, de sécurité et de sobriété.

La solution à cinq clusters est retenue malgré une silhouette inférieure, car elle offre le meilleur compromis entre séparation statistique, interprétabilité et valeur métier. Elle met notamment en évidence que **28 produits, soit 3,9 % du catalogue analysé, concentrent 123 148,73 € de stock, représentant 44,4 % de sa valeur**. Le clustering reste un outil exploratoire complémentaire aux règles métier et ne constitue pas une prédiction des ruptures futures.

Le croisement a posteriori avec le type de produit renforce la lecture métier : le profil de surstock est composé de 27 Champagnes sur 28 produits (96,4 %), le profil de ruptures actives de 19 Vins sur 20 (95,0 %) et le profil de stock nul de 23 Vins et d'un Whisky. La catégorie n'ayant pas été utilisée pour entraîner K-means, cette lecture reste descriptive et non causale.

2.6 Comparaison des outils de qualité des données

Les trois solutions sont comparées selon la qualité des contrôles, le temps de mise en œuvre, la reproductibilité, la sécurité et la conformité, la maintenabilité et la sobriété.

Option	Avantages	Limites / risques	Décision
Pandas – contrôles personnalisés	Déjà utilisé ; très flexible ; aucun nouvel outil.	Règles dispersées si elles ne sont pas structurées ; rapports à construire.	Retenu comme base du notebook.
Pandera	Schémas, types et règles explicites ; validation lazy ; intégration naturelle à Pandas.	Dépendance supplémentaire ; courbe d'apprentissage limitée ; maintenance du schéma.	Option privilégiée pour un POC de contrat de données réutilisable.
Great Expectations	Checkpoints, rapports Data Docs et gouvernance plus industrialisée.	Configuration et maintenance disproportionnées pour trois petits fichiers mensuels.	Écarté à ce stade ; pertinent si le périmètre et le nombre de pipelines augmentent.

DÉCISION APRÈS EXPÉRIMENTATION

Le POC Pandera a validé la base réelle sur 714 lignes et huit colonnes contrôlées. Sur une copie volontairement altérée, il a détecté six cas de non-conformité correspondant à cinq règles. Les contrôles Pandas sont conservés pour le profilage et les règles métier spécifiques ; Pandera est retenu comme couche complémentaire de validation structurelle réutilisable. Great Expectations reste différé, son niveau d'industrialisation étant disproportionné dans le périmètre actuel.

Les trois solutions peuvent être exécutées localement, sans transmission des données à un service externe. Sur le volume actuel, leur coût de calcul reste faible. Le POC confirme que Pandera présente le meilleur compromis entre formalisation, maintenabilité et sobriété dans le périmètre actuel.

2.7 Cadre d'utilisation critique de l'IA

Le recours à l'IA est encadré afin d'en exploiter les gains de productivité tout en préservant la fiabilité, la sécurité et la responsabilité de la décision humaine.

Dimension	Application au projet
Outil et rôle	ChatGPT en mode Work, avec les capacités de l'agent Codex, est utilisé comme assistant de code et de documentation. Il contribue à explorer des options, à proposer et refactoriser du code ainsi qu'à structurer les livrables. Il ne remplace ni l'analyse métier ni la décision de l'analyste.
Cas d'usage	Audit du notebook, propositions de refactorisation, comparaison de méthodes, aide à la documentation et génération de contrôles.
Gains observés	Accélération du brainstorming, amélioration de la lisibilité et élargissement du panel de solutions.
Contrôles humains	Exécution intégrale du notebook, rapprochement des totaux, vérification des formules et validation métier des anomalies.
Traçabilité	Conservation de prompts représentatifs, des variantes proposées, des résultats des tests, des corrections et des décisions prises.
Risques	Code incorrect, fausse assurance, surcomplexité, biais de formulation, dépendance à l'outil et exposition de données.
Sécurité / conformité	Les fichiers pédagogiques utilisés contiennent des données produit sans identifiant personnel. Aucune donnée personnelle, aucun mot de passe ni secret métier n'est transmis.
Mesures de maîtrise	Aucune décision automatique ; code exécuté et vérifié dans le notebook local ; sources conservées ; résultats rapprochés ; validation humaine avant conservation d'une proposition.

2.8 Système de veille et automatisation

Afin d'assurer une veille régulière, maintenable et proportionnée au besoin, un système de collecte automatisée est défini autour de Feedly et de flux RSS.

Élément	Choix
Outil	Feedly – lecteur de flux RSS et agrégateur de sources
Dossier proposé	Data Quality & IA
Sources prioritaires	Pandera, Great Expectations, pandas, SciPy, scikit-learn, CNIL et publications de référence sur la qualité des données.
Rythme	Lecture rapide hebdomadaire ; synthèse mensuelle ; mise à jour du tableau comparatif si une évolution est pertinente.
Règle de tri	Conserver uniquement les contenus fiables, datés, applicables au besoin et apportant une valeur méthodologique ou opérationnelle.
Preuve intégrée	Capture datée du dossier Feedly et des quatre flux officiels suivis, présentée en annexe C.
Responsable	L'analyste data assure la qualification, la synthèse et la mise à jour des informations collectées.

2.9 Sources fiables et datées

Les sources initiales privilégient la documentation officielle des outils et des bibliothèques étudiés. La date de consultation est conservée afin d'assurer la traçabilité de la veille.

Source	Référence	Apport	Date de consultation
Pandera	DataFrame Schemas	Schémas, types et contrôles de DataFrames	28/07/2026
Pandera	Lazy Validation	Agrégation des erreurs de validation	28/07/2026
Great Expectations	GX Core overview	Composants et logique de validation	28/07/2026
pandas	DataFrame.corr	Méthodes Pearson et Spearman	28/07/2026
SciPy	spearmanr	Définition et précautions d'interprétation	28/07/2026
CNIL	Définition d'une donnée personnelle	Cadre de qualification des données	28/07/2026
Feedly	News Reader	Agrégation de sources et flux de veille	28/07/2026
scikit-learn	PoissonRegressor	Régression généralisée adaptée à une cible de comptage et utilisant une fonction de lien logarithmique.	03/08/2026
scikit-learn	RandomForestRegressor	Modèle d'ensemble fondé sur plusieurs arbres de régression et contrôle de la reproductibilité.	03/08/2026
scikit-learn	KFold	Principe de la validation croisée en cinq partitions et paramètres de reproductibilité.	03/08/2026
scikit-learn	cross_val_predict	Production d'une prédiction hors échantillon pour chaque observation.	03/08/2026
scikit-learn	KMeans	Partitionnement non supervisé des observations et paramètres de reproductibilité.	04/08/2026
scikit-learn	silhouette_score	Évaluation de la cohésion et de la séparation des clusters afin de comparer plusieurs segmentations.	04/08/2026
scikit-learn	StandardScaler	Standardisation des variables numériques avant le clustering et la modélisation afin de rendre les échelles comparables.	04/08/2026
scikit-learn	LinearRegression	Régression linéaire comme référence interprétable et diagnostic des prédictions non contraintes.	09/08/2026

Ces références constituent le socle initial de la veille. Les nouvelles sources collectées par Feedly seront ajoutées au journal de veille après vérification de leur fiabilité, de leur date et de leur applicabilité.

Sources : documentations officielles des outils et bibliothèques étudiés, ainsi que l'autorité française de protection des données. Consultations réalisées entre le 28 juillet et le 9 août 2026.

3. Cahier des charges fonctionnel

Le projet vise à faire évoluer un rapprochement artisanal et difficilement contrôlable vers une analyse structurée, traçable et réutilisable.

3.1 État actuel et cible

Situation	Description
État actuel	Trois exports séparés — ERP, Web et table de liaison — avec des identifiants hétérogènes, des contrôles dispersés et des anomalies de saisie, de structure, de stock et de correspondance.
État cible	Une base analytique unique, contrôlée et traçable, préservant les valeurs sources, accompagnée d'indicateurs réconciliés, d'un journal d'anomalies priorisées et d'une procédure d'exécution reproductible.

3.2 Périmètre fonctionnel

Le périmètre fonctionnel définit les traitements, les données et les livrables couverts par la mission, ainsi que les éléments volontairement exclus.

Rubrique	Contenu
Inclus	Chargement, profilage, contrôle qualité, rapprochement ERP-Web, calculs de chiffre d'affaires, marges et stocks, journal d'anomalies, corrélations, POC prédictif du volume mensuel des ventes, segmentation non supervisée des profils de stock, recommandations et exports contrôlés.
Hors périmètre	Correction dans les systèmes sources, prévision opérationnelle des ruptures, industrialisation ou déploiement des modèles, automatisation de production, données clients et décisions automatiques de prix, de réapprovisionnement ou de déstockage.
Données	ERP (825 lignes), liaison (825 lignes), Web (1 513 lignes) ; situation au 31 octobre et ventes du mois d'octobre.
Livrables	Notebook amélioré ; documentation de la démarche ; base analytique, journal d'anomalies et prédictions exportés ; pipeline prédictif enregistré ; mini-formation ; preuves de veille.

3.3 Contraintes, ressources et budget

Le cadrage tient compte des contraintes de qualité et de temporalité des données, des ressources disponibles et de la nécessité de privilégier une solution proportionnée au besoin.

Contrainte / ressource	Hypothèse de cadrage
Qualité	Valeurs négatives, identifiants manquants, références obsolètes et catégories incomplètes.
Temporalité	Stock observé au 31 octobre et ventes limitées au seul mois d'octobre ; absence d'historique suffisant pour une analyse de tendance ou une prévision.
Délai / volumétrie	Mission courte ; fichiers de faible volumétrie ; priorité à une solution simple et maintenable.
Outillage	Python 3.12, Jupyter, pandas, NumPy, Matplotlib, Seaborn, OpenPyXL, scikit-learn, Joblib et Pandera ; exécution locale.
Sécurité / RGPD	Données produits et commerciales ; aucune donnée personnelle identifiée dans les champs utilisés.
Ressources	Une Data Analyst ; validation ponctuelle attendue du responsable vente et des équipes métier.
Budget – hypothèse	Aucun achat de licence additionnelle prévu. La charge de la Mission 1 est estimée à 6 jours-personne, à partir du notebook P6 existant et des trois fichiers sources ; détail en section 3.3.1.

3.3.1 Estimation de la charge de la Mission 1

La charge est estimée à partir du notebook P6 existant et des trois fichiers sources. Elle couvre l'amélioration technique, les expérimentations, les contrôles et la documentation de la Mission 1.

- **Cadrage – 0,5 jour** : analyse du besoin, du scénario et des fichiers disponibles.
- **Audit et qualité des données – 1 jour** : profilage, identification des anomalies, règles de contrôle et priorisation.
- **Amélioration du notebook – 1,5 jour** : refactorisation, rapprochement, indicateurs métier et visualisations.
- **Expérimentations et POC – 1 jour** : comparaisons IQR/Z-score et Pearson/Spearman, puis contrat de données Pandera.
- **Validation et exports – 0,5 jour** : tests, rapprochement des totaux, contrôle de la reproductibilité et fichiers de sortie.
- **Veille et documentation – 1 jour** : veille, cahier des charges, traçabilité de l'usage de l'IA et README.
- **Accompagnement – 0,5 jour** : mini-formation et finalisation des livrables.

Charge totale estimée : 6 jours-personne.

Cette estimation exclut la réalisation du portfolio, la préparation de la soutenance, les corrections dans les systèmes sources et la mise en production du pipeline. Elle constitue une hypothèse de cadrage à ajuster si le périmètre ou les données évoluent.

3.4 Critères d'acceptation

Les critères d'acceptation permettent de vérifier objectivement que le livrable répond aux exigences de qualité, de traçabilité, de reproductibilité et d'accompagnement des utilisateurs.

Dimension	Critère	Statut
Structure	714 produits et 36 colonnes dans l'export final ; aucun product_id manquant ou dupliqué.	Conforme
Réconciliation	CA TTC exporté égal au CA recalculé : 143 680,10 €.	Conforme
Traçabilité des données et de l'IA	41 anomalies consignées avec source, type, décision et action recommandée ; prompts représentatifs, variantes, résultats, corrections et décisions documentés.	Conforme
Reproductibilité	Restart Kernel + Run All sans erreur ni avertissement ; versions et paramètres documentés ; modèles réexécutable avec random_state=42 lorsque nécessaire.	Conforme
Interprétabilité	Méthodes, seuils, limites et décisions explicités dans le notebook et ce dossier.	Conforme
POC Pandera	Schéma de validation exécuté sur 714 lignes et huit colonnes contrôlées ; base réelle conforme et six cas de non-conformité détectés sur la copie de test.	Conforme
POC non supervisé	Comparaison de solutions comprises entre deux et six clusters ; solution à cinq clusters sélectionnée selon la silhouette et l'interprétabilité métier ; profils et produits concernés documentés.	Conforme
POC prédictif	Quatre modèles comparés par validation croisée ; régression linéaire diagnostiquée ; régression de Poisson sans stock retenue et coefficients interprétés ; 714 prédictions hors échantillon exportées ; scénario avec stock écarté en raison d'une fuite temporelle.	Conforme
Sécurité / conformité	Données pédagogiques sans donnée personnelle identifiée ; aucune décision automatique ; résultats vérifiés par l'analyste	Conforme
Veille automatisée	Dossier Feedly « Data Quality & IA » opérationnel, quatre flux officiels suivis et preuve datée intégrée en annexe C.	Conforme
Formation	Mini-plan adapté à un public non technique, intégrant les besoins d'accessibilité, notamment pour les collaborateurs en situation de handicap.	Conforme

L'ensemble des critères d'acceptation définis pour la Mission 1 est conforme. Les évolutions futures concernent la collecte de plusieurs mois de données et la validation chronologique du modèle avant tout usage opérationnel.

4. Pilotage du projet data

4.1 Lots, jalons et définition de Done

La Mission 1 est organisée en six lots de travail. Pour chaque lot, une définition de « Done » précise les conditions nécessaires à sa validation et permet de suivre objectivement l'avancement du projet.

Lot	Contenu	Définition de Done	Statut
L1 – Cadrage	Besoin, parties prenantes, périmètre, critères d'acceptation	Cahier des charges relu et cohérent avec la mission	Réalisé
L2 – Audit data	Profilage des trois sources et journal d'anomalies	Anomalies traçables, documentées et priorisées	Réalisé
L3 – Expérimentations et POC	Comparaisons IQR/Z-score et Pearson/Spearman ; POC prédictif ; segmentation K-means ; POC Pandera.	Résultats réconciliés ; méthodes comparées ; POCs exécutés, interprétés et documentés ; limites explicitées.	Réalisé
L4 – Veille	Sources, comparaison des solutions et automatisation Feedly	Choix justifiés, sources datées et preuve d'automatisation ajoutée	Réalisé
L5 – Documentation	Démarche IA, prompts, décisions, limites, reproductibilité et synthèse	Dossier complet, traçable, paginé et relu	Réalisé
L6 – Formation	Support et scénario pour utilisateurs non techniques	Mini-plan accessible finalisé, accompagné d'un guide métier, d'un cas pratique et d'un corrigé.	Réalisé

Les six lots de la Mission 1 sont achevés. Les évolutions futures concernent le suivi de la veille, l'enrichissement historique des données et l'intégration des preuves au portfolio de la Mission 2.

4.2 Backlog priorisé

Le backlog retrace les travaux priorisés et réalisés au cours de la Mission 1. Les tâches P1 ont conditionné directement la validation de la mission ; les tâches P2 ont porté sur la consolidation et la finalisation des livrables. La charge est estimée selon deux niveaux : S pour une charge courte ($\leq 0,5$ jour) et M pour une charge moyenne ($> 0,5$ à 1 jour).

Priorité	Tâche	Charge	Dépendance	Statut
P1	Finaliser la veille et le tableau de décision	M	Sources officielles	Réalisé
P1	Réaliser et documenter le POC Pandera ciblé	M	Notebook stabilisé et règles métier définies	Réalisé
P1	Comparer les modèles et documenter le POC prédictif	M	Base analytique stabilisée	Réalisé
P1	Mettre en place Feedly/RSS et capturer la preuve	S	Compte Feedly	Réalisé
P1	Stabiliser le cahier des charges et les critères d'acceptation	S	Analyse du besoin et résultats du notebook	Réalisé
P1	Finaliser le README et documenter l'environnement d'exécution	M	Notebook stabilisé	Réalisé
P2	Consolider le journal des prompts et décisions IA	M	Historique des échanges et des tests	Réalisé
P2	Créer la mini-formation accessible et son support pédagogique	M	Cahier des charges et résultats stabilisés	Réalisé
P2	Mettre à jour la grille qualité et finaliser la mise en page	S	Ensemble des livrables finalisés	Réalisé
P2	Réaliser un POC de segmentation K-means des profils de stock et de rotation	M	Base analytique stabilisée et indicateurs de stock calculés	Réalisé

Les tâches prévues pour la Mission 1 ont été réalisées. Les travaux ultérieurs relèvent de l'amélioration continue du projet et de la constitution du portfolio.

4.3 Registre initial des risques

Le registre recense les principaux risques susceptibles d'affecter la qualité, la sécurité, la reproductibilité et l'appropriation du livrable. La probabilité et l'impact sont évalués selon trois niveaux : faible, moyen et élevé.

ID	Risque	Prob.	Impact	Réponse
R1	Correction automatique d'une valeur atypique mais légitime	Moyenne	Élevé	Conserver la source et exiger une validation métier avant toute correction.
R2	Réponse IA incorrecte ou code non maîtrisé	Moyenne	Élevé	Exécuter, réconcilier et documenter chaque décision.
R3	Surdimensionnement de l'outillage qualité	Moyenne	Moyen	Conserver Pandera pour les contrôles structurels réutilisables et maintenir Great Expectations différé tant que le volume et le nombre de pipelines restent limités.
R4	Références manquantes ou obsolètes	Élevée	Moyen	Journaliser, exclure du rapprochement automatique et corriger à la source.
R5	Interprétation causale des corrélations	Moyenne	Élevé	Présenter l'analyse comme exploratoire et rappeler qu'elle porte sur un seul mois.
R6	Support peu accessible à un public non technique	Moyenne	Moyen	Utiliser un langage simple, des contrastes suffisants, des alternatives textuelles, un cas pratique et un corrigé.
R7	Exposition de données lors de l'utilisation d'un assistant IA	Faible	Élevé	Limiter les données transmises, exclure toute donnée personnelle ou confidentielle et privilégier les calculs locaux.
R8	Échec d'exécution lié aux versions ou aux dépendances	Moyenne	Élevé	Documenter l'environnement dans le README et valider l'installation avec pip check ainsi que Restart Kernel + Run All.
R9	Fuite temporelle liée à l'utilisation du stock de fin de mois	Moyenne	Élevé	Traiter le scénario avec stock comme analyse de sensibilité et l'écarter de la décision prédictive principale.
R10	Généralisation insuffisante du modèle à partir d'un seul mois.	Élevée	Élevé	Limiter le modèle à un POC, collecter plusieurs mois d'historique et réaliser une validation chronologique avant tout usage opérationnel.
R11	Surinterprétation ou instabilité des clusters calculés sur une seule période	Moyenne	Moyen	Conserver le clustering comme analyse exploratoire, maintenir les règles métier pour les listes d'action et vérifier la stabilité des groupes sur plusieurs mois avant toute utilisation récurrente.

Ce registre sera actualisé à chaque jalon du projet afin de suivre l'évolution des risques, l'efficacité des mesures prévues et l'apparition éventuelle de nouveaux risques.

4.4 Planning indicatif, jalons et points de contrôle

Le planning ci-dessous traduit l'estimation de six jours-personne présentée en section 3.3.1 en une séquence chronologique. Il s'agit d'une estimation professionnelle de la charge nécessaire à la réalisation de la Mission 1 à partir du notebook P6 existant ; elle ne correspond pas au temps pédagogique effectivement consacré au projet.

Période indicative	Charge	Lot de travail	Travaux principaux	Jalon ou point de contrôle
J1 – matin	0,5 jour	Cadrage	Analyse du besoin, des parties prenantes, des fichiers disponibles, du périmètre et des critères d'acceptation.	Cahier des charges initial relu et périmètre validé.
J1 – après-midi à J2 – matin	1,0 jour	Audit et qualité des données	Profilage des trois sources, identification, documentation et priorisation des anomalies.	Journal des anomalies contrôlé et rapprochement des sources vérifié.
J2 – après-midi à J3	1,5 jour	Amélioration du notebook	Refactorisation, rapprochements ERP-Web, indicateurs métier, visualisations et amélioration de la narration.	Restart Kernel + Run All sans erreur ; résultats et totaux réconciliés.
J4	1,0 jour	Expérimentations et POC	Comparaisons IQR/Z-score et Pearson/Spearman ; POC prédictif ; segmentation K-means ; validation Pandera.	Résultats comparés selon des critères communs et décisions méthodologiques documentées.
J5 – matin	0,5 jour	Validation et exports	Export, relecture et contrôle de la base analytique, du journal d'anomalies, des prédictions et des indicateurs.	Contrôles de structure, d'unicité, de complétude et de réconciliation conformes.
J5 – après-midi à J6 – matin	1,0 jour	Veille et documentation	Comparaison des outils et méthodes, collecte des sources, mise en place de Feedly, documentation de l'usage de l'IA et finalisation du README.	Sources et liens vérifiés ; preuve de veille ajoutée ; environnement documenté.
J6 – après-midi	0,5 jour	Accompagnement et finalisation	Préparation de la mini-formation, mise à jour des annexes, de la grille qualité et relecture finale des livrables.	Notebook, documentation et support de formation disponibles en version 1.1.

Le pilotage est réalisé de manière itérative : chaque modification importante du notebook est suivie d'une réexécution complète, d'un rapprochement des indicateurs et d'une mise à jour de la documentation. Le backlog de la section 4.2 et le registre des risques de la section 4.3 permettent de suivre les priorités, les dépendances, les écarts et les actions restantes.

5. Démarche IA et POC documenté

5.1 Hypothèse de travail

L'IA peut accélérer l'audit, la refactorisation et la documentation du notebook, à condition que les propositions soient comparées à une solution de référence, exécutées localement et validées par des contrôles chiffrés.

5.2 Traces initiales des essais

Le tableau ci-dessous constitue un journal synthétique des principaux essais réalisés avec l'appui de l'IA. Les propositions ont été exécutées localement, comparées et contrôlées avant toute décision de conservation.

Dans cette démarche, l'IA utilisée est ChatGPT en mode Work, avec les capacités de l'agent Codex pour l'analyse, la génération et la refactorisation du code ainsi que pour l'aide à la documentation. Les méthodes statistiques et les bibliothèques étudiées ne sont pas des outils d'IA : l'assistant a contribué à les identifier, à proposer leur implémentation et à structurer leur comparaison.

Essai	Prompt / besoin adressé à l'IA	Propositions / variantes de l'IA	Résultat	Décision
Audit et nettoyage	Analyser le notebook P6 afin d'identifier les redondances, les incohérences et les améliorations pertinentes.	Amélioration d'une copie de l'existant ou reconstruction de zéro ; propositions de code refactorisé et de narration Markdown.	Notebook restructuré et narration renforcée ; Run All sans erreur ; 714 produits, 36 colonnes, CA TTC de 143 680,10 € et 41 anomalies consignées.	Amélioration progressive retenue afin de préserver la traçabilité et de limiter le risque de régression.
Prix atypiques	Comparer IQR et Z-score sur les prix et justifier la méthode principale.	Implémentations IQR et Z-score proposées et comparées.	31 prix signalés par IQR contre 13 par Z-score ; les 13 valeurs appartiennent également au groupe IQR.	IQR retenu comme méthode principale ; Z-score conservé comme contrôle complémentaire.
Corrélations	Comparer Pearson et Spearman sur le prix de vente, le prix d'achat, le stock et les ventes.	Implémentations Pearson et Spearman proposées et comparées.	Sur 713 observations communes, Spearman révèle notamment stock-ventes = 0,76 et prix-ventes = -0,70.	Spearman retenu pour l'interprétation principale ; Pearson conservé comme contrôle complémentaire.
POC prédictif	Identifier des modèles adaptés à la prédiction d'un volume de ventes et construire un protocole limitant les biais.	Quatre modèles ; scénarios avec et sans stock ; validation croisée à cinq partitions ; coefficients du modèle de Poisson.	Sans stock : Poisson, MAE 2,46 et R^2 0,36 ; régression linéaire, R^2 -0,08 et dix prédictions négatives. Avec stock : forêt aléatoire, R^2 0,70, mais fuite temporelle.	Poisson sans stock retenue ; régression linéaire conservée comme comparaison ; scénario avec stock écarté ; aucun usage opérationnel.
Qualité automatisée	Comparer des outils de validation proportionnés au cas BottleNeck et proposer un test contrôlé.	Pandas, Pandera et Great Expectations ; schéma Pandera et création d'une copie volontairement invalide.	Base réelle conforme sur 714 lignes et huit colonnes ; six cas de non-conformité détectés sur cinq règles dans la copie de test.	Pandas conservé pour les contrôles métier ; Pandera retenu comme couche structurelle complémentaire ; Great Expectations différé.
Segmentation non supervisée	Identifier automatiquement des profils de ventes, de stock et d'immobilisation financière, puis comparer plusieurs nombres de clusters	Transformation logarithmique, standardisation et comparaison de solutions K-means comprises entre deux et six clusters à partir de l'inertie, de la silhouette et de l'interprétabilité métier.	Deux clusters : meilleure silhouette (0,697). Cinq clusters : lecture métier plus utile (0,541), 20 ruptures sur 22 isolées et 27 Champagnes sur 28 produits dans le profil de surstock.	Solution à cinq clusters retenue comme analyse exploratoire complémentaire ; règles métier conservées pour les listes exhaustives ; aucune prédiction de rupture.

Ces premiers essais montrent que l'IA a principalement contribué à explorer et à structurer les options. Les décisions ont toutefois été fondées sur l'exécution du code, les résultats chiffrés et l'analyse critique de leur pertinence métier.

5.3 Critères d'évaluation communs

Une grille commune est appliquée aux méthodes, outils et propositions issus de l'IA afin de garantir une comparaison cohérente et de rendre les décisions explicites.

Critère	Éléments évalués
Qualité	Exactitude, couverture du besoin métier et lisibilité du résultat.
Robustesse / biais	Sensibilité aux valeurs extrêmes, hypothèses statistiques, faux positifs et risques d'interprétation.
Temps / coût	Temps de conception, d'exécution et de prise en main ; éventuels coûts de licence et de maintenance.
Reproductibilité	Règles déterministes, environnement documenté et contrôles réexécutable.
Sécurité / conformité	Calcul local, minimisation des données, respect du cadre applicable et absence de décision automatique.
Maintenabilité	Simplicité du code, dépendances et facilité d'évolution.
Sobriété	Proportionnalité de l'outil au besoin et coût de calcul limité.

Cette grille est utilisée pour comparer les méthodes statistiques, les outils de qualité des données et les propositions produites avec l'appui de l'IA.

5.4 Limites des POC et de la démarche

Les POC permettent de démontrer la faisabilité et l'intérêt des améliorations proposées, mais leurs résultats doivent être interprétés en tenant compte des limites suivantes :

- Une seule période d'observation est disponible ; les résultats ne permettent pas d'évaluer la saisonnalité ni d'être généralisés à d'autres périodes.
- Les anomalies signalées ne constituent pas automatiquement des erreurs : plusieurs nécessitent une validation métier.
- Les propositions produites avec l'appui de l'IA dépendent de la formulation des prompts et peuvent contenir des erreurs ou introduire une complexité inutile.
- Le POC Pandera a été exécuté sur huit colonnes de la base analytique. Le schéma devra être maintenu et adapté si la structure des fichiers ou les règles métier évoluent. Les fichiers présentent une faible volumétrie ; la performance et la maintenabilité sur un périmètre industrialisé ne sont pas testées.
- Les données sources ne sont pas corrigées directement : les exclusions et transformations sont réalisées uniquement dans la base analytique.
- Le POC prédictif repose sur un seul mois et sur une validation croisée non chronologique ; il ne permet donc pas de garantir la performance sur une période future.
- La régression de Poisson surestime les produits sans vente et sous-estime les références à forte rotation. Elle est conservée comme preuve de faisabilité, sans usage opérationnel.
- La segmentation K-means dépend des variables sélectionnées, de leur transformation et de la période observée. Les libellés métier sont attribués après l'apprentissage et la stabilité des cinq clusters n'a pas été vérifiée sur plusieurs mois. Le clustering est donc conservé comme outil exploratoire complémentaire aux règles métier.

Les prompts représentatifs, les principales variantes et les captures des résultats sont conservés en annexe afin de compléter la traçabilité de la démarche.

6. Mini-formation à destination des métiers

Objectif : permettre à un utilisateur non technique de comprendre les principaux indicateurs, d'interpréter le journal d'anomalies et d'identifier les actions à engager sans modifier le code.

Élément	Dispositif retenu
Public	Responsable des ventes, équipes commerciales et de gestion des stocks, membres du CODIR.
Prérequis	Aucun prérequis en Python ou en analyse de données.
Durée	45 minutes : 10 min de contexte, 15 min d'indicateurs, 10 min d'anomalies, 10 min de mise en pratique.
Compétences visées	Lire les statuts de qualité, distinguer une anomalie d'une erreur, prioriser une action et comprendre les limites de l'analyse.
Support	Guide synthétique d'une page, démonstration guidée des résultats du notebook sans présentation du code et export du journal d'anomalies.
Accessibilité	Langage simple, contraste élevé, police lisible, tableaux titrés, alternatives textuelles, document numérique structuré et absence de dépendance à la couleur seule. Les éléments visuels sont également expliqués oralement.
Évaluation	Cas pratique court, reformulation par l'utilisateur et collecte d'un retour sur la compréhension.
Critère de réussite	L'utilisateur identifie correctement le statut, la nature de l'anomalie et l'action appropriée dans au moins trois cas sur quatre.

Ce mini-plan fournit aux utilisateurs métiers un cadre structuré pour comprendre les indicateurs, interpréter les anomalies et identifier les actions appropriées. Le guide, le cas pratique et le corrigé permettent son utilisation lors d'une session de sensibilisation de 45 minutes.

7. Reproductibilité, sécurité, conformité et sobriété

Les éléments ci-dessous documentent les conditions d'exécution, les mesures de traçabilité et de sécurité ainsi que les choix de sobriété appliqués au projet.

Dimension	Preuve / disposition
Environnement	Python 3.12.9 ; pandas 2.3.3 ; NumPy 2.3.5 ; Matplotlib 3.10.7 ; Seaborn 0.13.2 ; OpenPyXL 3.1.5 ; scikit-learn 1.9.0 ; Joblib 1.5.3 ; Pandera 0.32.1.
Exécution	Restart Kernel + Run All validé ; toutes les cellules ont été exécutées sans erreur ni avertissement ; contrôles finaux et fichiers exportés conformes.
Déterminisme	Les règles de contrôle sont déterministes. La validation croisée, la forêt aléatoire et le clustering utilisent <code>random_state=42</code> ; K-means utilise également <code>n_init=20</code> . La régression de Poisson retenue est déterministe.
Traçabilité	Sources brutes préservées ; colonnes d'analyse séparées ; journal d'anomalies exporté ; prédictions hors échantillon conservées ; clusters rattachés aux <code>product_id</code> ; résultats réconciliés.
Instructions d'exécution	Notebook structuré et ordonné ; README et fichier <code>requirements.txt</code> finalisés ; environnement contrôlé avec <code>pip check</code> ; Restart Kernel + Run All exécuté sans erreur ni avertissement.
Sécurité / RGPD	Données pédagogiques relatives aux produits et aux activités commerciales ; aucune donnée personnelle identifiée ; seuls les fichiers nécessaires ont été utilisés, sans identifiant personnel, mot de passe ou donnée client.
Sobriété	Traitement local de fichiers de faible volumétrie ; méthodes proportionnées au besoin ; POC prédictif non industrialisé ; clustering limité à trois variables ; Great Expectations différé car surdimensionné pour le périmètre actuel.
Gestion des versions	Notebook P6 original conservé ; version améliorée distincte ; exports et documentation nommés explicitement.

Les POC prédictif et Pandera ont été exécutés et leurs dépendances sont documentées. Le README rassemble les instructions d'installation et d'exécution. Le contrôle Restart Kernel + Run All ainsi que la vérification de l'environnement avec `pip check` ont été réalisés sans erreur.

8. Synthèse recruteur/client

Besoin traité

BottleNeck disposait de trois exports distincts, comportant des identifiants hétérogènes et des anomalies susceptibles d'affecter les indicateurs commerciaux. L'objectif était de produire une base analytique unique, contrôlée et reproductible, puis de transformer les résultats en recommandations utiles aux équipes métier.

Valeur ajoutée démontrée

Le notebook pédagogique initial a été transformé en un livrable orienté vers la décision : rapprochement des sources, contrôle de la qualité, traçabilité des anomalies, comparaison critique des méthodes, analyse des ventes, des marges et des stocks, expérimentation d'un modèle prédictif et segmentation non supervisée des profils de stock et de rotation. ChatGPT/Codex a été utilisé comme assistant de code, de comparaison et de documentation. Les propositions ont été exécutées localement, confrontées aux résultats chiffrés et validées par l'analyste avant leur conservation.

Résultats clés

- Une base analytique de **714 produits et 36 colonnes**, sans `product_id` manquant ou dupliqué.
- Un chiffre d'affaires TTC d'octobre de **143 680,10 €**, correspondant à **5 751 unités vendues**.
- **41 anomalies documentées**, dont **18 classées en priorité haute**.
- Un stock ERP valorisé à **298 627,66 €** au prix d'achat, représentant environ **119 jours de couverture financière**.
- **27 produits** présentant un risque d'immobilisation financière et **22 produits vendus mais en rupture de stock**.
- L'IQR retenu pour la détection principale des prix atypiques et Spearman pour l'interprétation principale des corrélations.
- Quatre modèles prédictifs comparés par validation croisée. La régression de Poisson sans stock est retenue pour le POC avec une MAE de 2,46 unités, un RMSE moyen de 3,31 et un R^2 de 0,36. La régression linéaire est conservée comme comparaison pédagogique, les coefficients du Poisson sont interprétés et le scénario avec stock est écarté pour fuite temporelle.
- Un POC Pandera validant **714 lignes et huit colonnes** de la base réelle. Le test sur une copie volontairement invalide a détecté **six cas de non-conformité correspondant à cinq règles**.
- Un POC de segmentation non supervisée compare des solutions comprises entre deux et six clusters. La solution à cinq clusters est retenue pour son utilité métier : 28 produits concentrent 44,4 % de la valeur du stock analysé et 20 des 22 ruptures actives sont isolées. Le croisement par catégorie montre que 27 des 28 produits du profil de surstock sont des Champagnes.
- Un notebook reproductible dont toutes les cellules s'exécutent intégralement sans erreur ni avertissement après Restart Kernel + Run All.

Recommandations prioritaires

- Corriger en priorité les anomalies de prix, de stock et de liaison dans les systèmes sources.
- Réapprovisionner les références vendues en rupture selon leur contribution aux ventes et à la marge.
- Réduire le stock sans vente ou présentant plus de douze mois de couverture.
- Maintenir les contrôles Pandas pour le profilage et les règles métier, complétés par Pandera pour le contrôle automatisé du schéma.
- Ne pas utiliser le modèle prédictif pour une décision opérationnelle tant que des historiques sur plusieurs mois et une validation temporelle ne sont pas disponibles.
- Utiliser les clusters comme aide à la priorisation des analyses de rupture et d'immobilisation, tout en conservant les règles métier pour établir les listes exhaustives de produits concernés.

Prochaines étapes

- Maintenir la veille automatisée dans Feedly et consigner les évolutions pertinentes des bibliothèques suivies.
- Collecter plusieurs mois de données afin d'évaluer la saisonnalité, de réaliser une validation chronologique du modèle prédictif et de vérifier la stabilité des clusters.
- Enrichir le modèle avec des variables historiques pertinentes avant d'envisager une utilisation opérationnelle.
- Mettre à jour la grille qualité et intégrer les principales preuves de compétences au portfolio.

Annexe A – Grille de couverture finale

Indicateur	Preuve	Statut
Veille comparée et justifiée	Sections 2.5 à 2.7	Réalisé
Sources fiables et datées	Section 2.9	Réalisé
Sobriété / développement durable	Sections 2.6 et 7	Réalisé
Automatisation de la veille	Section 2.8 + capture Feedly Annexe C	Réalisé
Besoin métier et priorités	Section 1	Réalisé
Cahier des charges complet	Section 3	Réalisé
Pilotage, backlog et risques	Section 4	Réalisé
POC, essais IA et décisions	Section 5 + notebook + annexe B	Réalisé
Apprentissage supervisé et non supervisé	Sections 2.5.3 et 2.5.4 + notebook	Réalisé
Mini-formation accessible	Section 6 + support pédagogique	Réalisé
Reproductibilité et conformité	Section 7 + notebook + README	Réalisé

Fin de la version 1.1 — La Mission 1 est finalisée et les retours du mentor ont été intégrés : notebook amélioré, veille automatisée, cahier des charges, pilotage, POC documentés, mini-formation, reproductibilité et annexes de traçabilité.

Annexe B – Traces représentatives des échanges avec l’IA

Les traces ci-dessous présentent une sélection de cinq échanges représentatifs de l’utilisation de ChatGPT en mode Work avec les capacités de l’agent Codex. Elles ne reproduisent pas l’intégralité des échanges, mais documentent les principaux besoins adressés à l’IA, les propositions obtenues, les vérifications réalisées et les décisions prises par l’analyste.

Les échanges ont été conduits principalement en portugais, langue de travail choisie par l’analyste. Leur objet et leurs conclusions sont reformulés en français afin de faciliter leur lecture par l’évaluateur.

Trace	Objet de l’échange	Contribution démontrée
B1	Audit et refactorisation du notebook P6	Identification des redondances, proposition d’une structure améliorée et renforcement de la narration.
B2	Comparaison des méthodes statistiques	Comparaison IQR/Z-score et Pearson/Spearman selon des critères explicites.
B3	POC prédictif	Comparaison initiale des modèles, puis ajout de la régression linéaire, diagnostic de ses limites, analyse des coefficients du Poisson et décision sur la fuite temporelle.
B4	POC Pandera	Comparaison de Pandas, Pandera et Great Expectations ; validation du schéma sur la base réelle et sur une copie volontairement non conforme.
B5	Segmentation non supervisée	Comparaison de plusieurs nombres de clusters, arbitrage entre performance statistique et utilité métier, puis identification des limites.

Capture B1 – Extrait du prompt et de la proposition d’audit du notebook

Ces prompts de revue finale reprennent fidèlement les besoins traités, sans se substituer au journal synthétique des essais présenté en section 5.2.

Agis comme un Data Analyst senior chargé de réviser le notebook P6 BottleNeck. Compare deux options : reconstruire entièrement le notebook ou améliorer progressivement une copie de l'existant. Évalue ces options selon la qualité, le risque de régression, le temps nécessaire, la reproductibilité, la maintenabilité et la sécurité. Recommande une option et précise les contrôles nécessaires avant validation.

Comparaison des options

Critère	Reconstruction complète	Amélioration progressive
Qualité	Structure potentiellement plus homogène, mais risque d'oublier certaines règles métier existantes.	Conservation des traitements validés et amélioration ciblée des points faibles.
Risque de régression	Élevé : les calculs et jointures doivent être entièrement revalidés.	Limité : les résultats peuvent être comparés progressivement à ceux du P6.
Temps	Important, avec réécriture et tests complets.	Plus court, car les éléments fiables sont réutilisés.
Reproductibilité	Possible, mais à reconstruire intégralement.	Renforcée par la réorganisation du notebook et l'ajout de contrôles finaux.
Maintenabilité	Bonne si la reconstruction est parfaitement documentée.	Bonne si les redondances sont supprimées et les règles centralisées.
Sécurité	Calcul local possible dans les deux cas.	Conservation des sources brutes et limitation des transformations inutiles.

Recommandation

Retenir l'amélioration progressive d'une copie du notebook P6. Cette option préserve la traçabilité, réduit le risque de régression et permet de justifier précisément chaque modification apportée avec l'aide de l'IA.

Contrôles avant validation

- conserver les fichiers sources et le notebook P6 sans modification ;
- exécuter `Restart Kernel + Run All` sans erreur ni avertissement ;
- vérifier les 714 produits, les 36 colonnes et l'unicité des `product_id` ;
- réconcilier le chiffre d'affaires TTC de 143 680,10 € ;
- vérifier les 41 anomalies consignées ;
- contrôler les exports et documenter les versions de l'environnement.

📄 👍 🗨️ 🔗 ↺ ⋮

ChatGPT peut faire des erreurs. Vérifiez les informations importantes.

Agis comme un Data Analyst senior et analyse deux comparaisons méthodologiques réalisées sur les données BottleNeck. Pour la détection des prix atypiques, compare l'IQR avec un coefficient de 1,5 et le Z-score avec un seuil de 3 : 31 prix sont détectés par l'IQR contre 13 par le Z-score, et les 13 appartiennent également au groupe IQR. Pour les corrélations, compare Pearson et Spearman sur 713 observations, notamment stock-ventes (0,44 contre 0,76) et prix-ventes (-0,52 contre -0,70). Évalue la qualité, la robustesse aux valeurs extrêmes, les biais, l'interprétabilité, le temps de calcul, la reproductibilité, la sécurité et la sobriété. Recommande une méthode principale et une méthode complémentaire pour chaque analyse, en précisant les limites d'interprétation.

Afficher moins ^

1. Détection des prix atypiques

Critère	IQR – coefficient 1,5	Z-score – seuil 3
Adaptation	Convient aux distributions asymétriques et ne suppose pas une distribution normale.	Plus adapté à une distribution proche de la normale.
Robustesse	Peu influencé par les valeurs extrêmes.	Moyenne et écart-type influencés par les prix élevés.
Résultat	31 prix détectés, avec un risque de signaler des produits premium légitimes.	13 prix détectés, tous également présents dans le groupe IQR ; risque de sous-détection.
Interprétabilité	Seuil fondé sur les quartiles, simple à expliquer.	Seuil exprimé en nombre d'écarts-types, également reproductible.

Décision : retenir l'IQR comme méthode principale et conserver le Z-score comme contrôle complémentaire. Les 13 références communes représentent les valeurs les plus extrêmes. Aucun prix ne doit être corrigé automatiquement : une valeur atypique n'est pas nécessairement une erreur.

2. Analyse des corrélations

Critère	Pearson	Spearman
Principe	Mesure l'intensité d'une relation linéaire.	Mesure une relation monotone à partir du rang des observations.
Robustesse	Sensible aux valeurs extrêmes.	Moins influencé par les valeurs extrêmes et les distributions asymétriques.
Stock-ventes	0,44 : relation linéaire positive modérée.	0,76 : relation monotone positive forte.
Prix-ventes	-0,52 : relation linéaire négative modérée.	-0,70 : relation monotone négative forte.

Décision : retenir Spearman comme méthode principale d'interprétation et conserver Pearson comme contrôle complémentaire. Les écarts entre les coefficients indiquent que les relations sont partiellement non linéaires ou influencées par des observations extrêmes.

Critères communs et limites

Les quatre calculs sont locaux, déterministes, rapides, reproductibles et présentent un coût de calcul ainsi qu'un impact environnemental négligeables sur ce volume de données.

Les corrélations décrivent des associations et non des causalités. Elles reposent sur un seul mois de ventes. De même, les 31 prix signalés par l'IQR doivent être soumis à une validation métier avant toute décision.

📄 👍 🗨️ 🔗 🔄 ⋮

Capture B3 – POC prédictif : première comparaison

Cette trace présente la première comparaison du POC. Le retour mentor du 9 août a ensuite conduit à ajouter la régression linéaire, à diagnostiquer ses prédictions et à interpréter les coefficients du modèle de Poisson ; les résultats consolidés figurent en section 2.5.3.

Agis comme un Data Analyst senior et évalue un POC de prédiction du volume mensuel des ventes réalisé sur 714 produits BottleNeck. Trois modèles ont été comparés par validation croisée à cinq partitions : une référence naïve, une régression de Poisson et une forêt aléatoire. Sans utiliser le stock, la référence naïve obtient un MAE de 3,26 et un R^2 de -0,01, la régression de Poisson un MAE de 2,46 et un R^2 de 0,36, et la forêt aléatoire un MAE de 2,52 et un R^2 de 0,29. Dans un scénario de sensibilité incluant le stock disponible au 31 octobre, la forêt aléatoire atteint un MAE de 1,45 et un R^2 de 0,70. Compare les modèles selon la qualité, les biais, l'interprétabilité, le risque de fuite de données, le temps de calcul, la reproductibilité, la sécurité, la maintenabilité et la sobriété. Recommande le modèle à conserver et précise si son utilisation opérationnelle est justifiée.

Afficher moins ^

Comparaison des modèles

Modèle / scénario	Qualité observée	Avantages	Limites et risques
Référence naïve	MAE : 3,26 ; R^2 : -0,01	Simple, rapide et utile comme niveau minimal de comparaison.	N'explique pratiquement aucune variabilité des ventes.
Régression de Poisson sans stock	MAE : 2,46 ; R^2 : 0,36	Adaptée à une cible de comptage, relativement interprétable et meilleure performance du scénario principal.	Performance modérée ; surestimation des ventes nulles et sous-estimation des fortes ventes.
Forêt aléatoire sans stock	MAE : 2,52 ; R^2 : 0,29	Capte les relations non linéaires.	Performance inférieure à Poisson, interprétabilité et maintenabilité plus limitées.
Forêt aléatoire avec stock	MAE : 1,45 ; R^2 : 0,70	Meilleure performance apparente.	Résultat non exploitable pour une prévision préalable aux ventes en raison d'une fuite temporelle.

Analyse critique

Le stock disponible au 31 octobre a déjà été influencé par les ventes réalisées pendant le mois. Il ne serait donc pas connu au moment d'une prévision effectuée avant octobre. Son utilisation améliore artificiellement la performance et doit rester limitée à une analyse de sensibilité.

Les modèles sont exécutés localement sur des données sans information personnelle. Leur coût de calcul est faible. La validation croisée à cinq partitions et le paramètre `random_state=42` assurent la reproductibilité des comparaisons. La régression de Poisson présente également le meilleur compromis entre performance, interprétabilité, maintenabilité et sobriété.

Décision

Retenir la régression de Poisson sans stock pour le POC. Elle améliore nettement la référence naïve, avec une réduction du MAE de 3,26 à 2,46 et un R^2 positif de 0,36.

Son utilisation opérationnelle n'est toutefois pas justifiée dans les conditions actuelles. Les données ne couvrent qu'un seul mois, aucune validation chronologique sur une période future n'a été réalisée et le modèle présente des biais importants sur les ventes nulles et les références à forte rotation.

Le modèle est donc conservé comme preuve de faisabilité technique, sous réserve de collecter plusieurs mois d'historique et d'effectuer une validation chronologique avant tout déploiement.

📄 👍 🗨️ 🔗 🔄 ⋮

Capture B4 – POC Pandera

Ce prompt de revue finale évalue la valeur ajoutée du schéma Pandera et formalise l’arbitrage entre les trois solutions de contrôle étudiées.

Agis comme un Data Analyst senior et évalue trois solutions de contrôle de la qualité des données pour le projet BottleNeck, composé de trois petits fichiers mensuels : contrôles personnalisés avec Pandas, schéma de validation Pandera et Great Expectations. Un POC Pandera a été exécuté sur la base analytique réelle : 714 lignes et huit colonnes contrôlées ont été validées sans non-conformité. Une copie volontairement invalide a ensuite été créée avec un `product_id` dupliqué, un prix négatif, des ventes négatives, une valeur `onsale_web` égale à 2 et une catégorie manquante. Pandera a détecté six cas de non-conformité correspondant à cinq règles. Compare les trois solutions selon la qualité des contrôles, la lisibilité des erreurs, le temps de mise en œuvre, la courbe d'apprentissage, la reproductibilité, la maintenabilité, la sécurité et la sobriété. Indique si Pandera doit remplacer ou compléter les contrôles Pandas et si la mise en œuvre de Great Expectations est justifiée dans ce périmètre.

Afficher moins ^

Réfléchi pendant 32s >

Comparaison des solutions

Critère	Pandas – contrôles personnalisés	Pandera	Great Expectations
Qualité	Très flexible pour les jointures, le profilage et les règles métier spécifiques.	Schéma centralisé pour les types, l'unicité, les valeurs autorisées et les bornes.	Validation structurée avec une logique davantage orientée pipeline et gouvernance.
Lisibilité des erreurs	Dépend des messages et tableaux programmés par l'analyste.	<code>Lazy=True</code> permet de regrouper les non-conformités dans un même rapport.	Résultats de validation pouvant être restitués dans une documentation dédiée.
Mise en œuvre	Immédiate, car Pandas est déjà utilisé dans le notebook.	Faible coût initial : définition et maintenance d'un schéma.	Configuration plus importante : contexte, validations, checkpoints et actions.
Courbe d'apprentissage	Faible.	Limitée pour un utilisateur de Pandas.	Plus élevée et adaptée à une démarche plus industrialisée.
Reproductibilité	Bonne si les règles sont correctement centralisées.	Forte : schéma explicite, réutilisable et réexécutable.	Forte dans un environnement comportant plusieurs pipelines.
Maintenabilité	Risque de dispersion des règles dans le notebook.	Contrôles structurels regroupés dans un seul contrat de validation.	Pertinent pour une équipe, plusieurs sources et des contrôles récurrents.
Sécurité	Exécution locale.	Exécution locale.	Exécution locale possible, mais avec davantage de composants à administrer.
Sobriété	Coût négligeable.	Dépendance supplémentaire limitée et proportionnée au besoin.	Surdimensionné pour trois petits fichiers mensuels dans le périmètre actuel.

Pandera permet de définir un schéma de `DataFrame` et de collecter plusieurs erreurs en une seule validation avec `Lazy=True`. Great Expectations positionne notamment ses Checkpoints comme mécanisme de validation destiné aux déploiements de production. [Documentation Pandera](#) , [Lazy Validation](#) , [GX Core](#) .

Résultat du POC

La base réelle a été validée sur **714 lignes et huit colonnes contrôlées**, sans non-conformité. Sur la copie volontairement altérée, Pandera a détecté **six cas de non-conformité correspondant à cinq règles**.

L'unicité du `product_id` produit deux lignes d'erreur, car Pandera signale les deux enregistrements portant la même valeur dupliquée. Les quatre autres règles concernent le prix, les ventes, `onsale_web` et la catégorie obligatoire.

Décision

Pandera ne doit **pas remplacer Pandas**, mais le compléter :

- **Pandas** est conservé pour le profilage, les rapprochements et les règles métier spécifiques ;
- **Pandera** est retenu pour les contrôles structurels centralisés et réutilisables ;
- **Great Expectations** est différé, car son niveau de configuration et d'industrialisation est disproportionné pour le périmètre actuel.

Great Expectations pourrait être réévalué si le nombre de fichiers, de pipelines, d'utilisateurs ou d'exigences de gouvernance augmentait.



ChatGPT peut faire des erreurs. Vérifiez les informations importantes.

 Travaillez sur n'importe quoi

5,6 Sol Très élevée 



Page 28

Capture B5 – POC de segmentation non supervisée des profils de stock

Projeto 13 Work · Work

Agis comme un Data Analyst senior et évalue un POC de segmentation non supervisée réalisé sur 713 produits BottleNeck. Trois variables ont été utilisées : les quantités vendues en octobre, le stock disponible au 31 octobre et sa valeur au prix d'achat. Les variables ont été transformées avec log1p, puis standardisées avec StandardScaler avant l'application de K-means.

Des solutions comprises entre deux et six clusters ont été comparées à partir de l'inertie et du coefficient de silhouette. La solution à deux clusters obtient la meilleure silhouette, avec 0,697, mais sépare principalement les produits disposant d'un stock des produits à stock faible ou nul. La solution à cinq clusters obtient une silhouette de 0,541, mais distingue des profils de rotation soutenue, de stock nul, de ruptures actives, de rotation faible et de surstock.

Avec cinq clusters, un groupe isole 20 des 22 ruptures actives. Un autre groupe rassemble 28 produits, soit 3,9 % du catalogue analysé, représentant 123 148,73 € et 44,4 % de la valeur du stock analysé ; il concentre également 24 des 27 risques d'immobilisation.

Compare les solutions à deux et cinq clusters selon la qualité, la robustesse et les biais, l'interprétabilité, le temps de calcul, la reproductibilité, la sécurité, la maintenabilité et la sobriété. Indique si le choix de cinq clusters est justifié malgré un coefficient de silhouette inférieur, précise la contribution réelle du clustering par rapport aux règles métier et présente les limites d'utilisation de cette segmentation.

Afficher moins ^



La solution à cinq clusters est justifiée pour une utilisation exploratoire métier, malgré une silhouette inférieure. Le choix repose sur un compromis explicite entre séparation statistique et capacité d'action.

Critère	2 clusters	5 clusters	Évaluation
Qualité statistique	Silhouette de 0,697 : groupes nettement séparés.	Silhouette de 0,541 : séparation moins forte mais encore satisfaisante.	Avantage statistique à deux clusters.
Interprétabilité	Séparation générale entre produits avec stock et produits à stock faible ou nul.	Cinq profils distincts de rotation, rupture et surstock.	Avantage métier à cinq clusters.
Robustesse / biais	Structure plus stable, mais risque de masquer des différences internes.	Plus sensible aux variables, transformations et données observées.	Validation sur plusieurs périodes nécessaire.
Résultat opérationnel	Ruptures et stocks nuls restent regroupés.	20 des 22 ruptures actives sont isolées ; 24 des 27 risques d'immobilisation sont concentrés dans un cluster.	Les cinq clusters facilitent la priorisation.
Temps de calcul	Négligeable sur 713 observations.	Négligeable sur 713 observations.	Différence non significative.
Reproductibilité	Réexécutable avec les mêmes données et paramètres.	n_init=20 et random_state=42 stabilisent le résultat.	Reproductible dans l'environnement documenté.
Sécurité	Calcul local, sans donnée personnelle.	Calcul local, sans donnée personnelle.	Niveau équivalent.
Maintenabilité	Solution simple.	Cinq profils et leurs libellés doivent être suivis dans le temps.	Maintenabilité acceptable.
Sobriété	Trois variables et un algorithme léger.	Même environnement et même faible coût de calcul.	Niveau équivalent.

Décision

La solution à cinq clusters est retenue parce qu'elle produit des groupes plus actionnables. Le cluster de surstock rassemble seulement 28 produits, mais concentre 123 148,73 €, soit 44,4 % de la valeur du stock analysé. Cette concentration constitue une information importante pour prioriser les analyses commerciales et financières.

Contribution réelle du clustering

Le clustering ne remplace pas les règles métier. Celles-ci restent plus transparentes pour établir les listes exhaustives des 22 ruptures et des 27 risques d'immobilisation. Le clustering apporte une lecture complémentaire : il regroupe les produits ayant des comportements similaires, révèle les concentrations de risque et facilite la priorisation.

Limites

- Les résultats reposent sur une seule période et un stock observé au 31 octobre.
- Les clusters dépendent des variables choisies et de leur transformation.
- Les libellés métier sont attribués après l'apprentissage.
- Leur stabilité n'a pas été testée sur plusieurs mois.
- Cette segmentation décrit la situation observée ; elle ne prédit pas les ruptures futures.

Le POC est donc conservé comme outil exploratoire d'aide à l'analyse, sans automatisation des décisions.

     |  Convert to PDF

ChatGPT peut faire des erreurs. Vérifiez les informations importantes.

+

travaillez sur n'importe quoi

5.6 Sol Très élevée ▾





Annexe C – Preuve d’automatisation de la veille

Un dossier intitulé « **Data Quality & IA** » a été créé dans Feedly afin de centraliser automatiquement les nouvelles versions des principales bibliothèques et solutions étudiées dans le projet.

Quatre flux officiels sont suivis : Pandera, pandas, scikit-learn et Great Expectations. Cette organisation permet d’identifier les évolutions susceptibles d’affecter la reproductibilité, la qualité ou la maintenabilité du notebook.

La collecte est automatisée par Feedly. Les informations restent ensuite qualifiées par l’analyste avant toute décision de mise à jour d’une dépendance ou d’évolution de la méthode.

Figure C1 – Dossier Feedly « Data Quality & IA » regroupant automatiquement les nouvelles versions de Pandera, pandas, scikit-learn et Great Expectations. Capture réalisée le 3 août 2026.

