

Projet 8 — OpenClassrooms

Analyse de l'évolution du profil sociodémographique des étudiants Data

Workflow DBT documenté

Préparé par : Joana d'Arc Soares Aubry

Rôle : Data Analyst Junior

Formation : Data Analyst — OpenClassrooms

Date : mai 2026

Objectif : documenter les traitements DBT, les choix méthodologiques et les contrôles Snowflake permettant de reproduire l'analyse.

Sommaire

1. 1. Objectif du workflow
2. 2. Environnement technique
3. 3. Organisation générale du pipeline DBT
4. 4. Sources de données
5. 5. Couche sources
6. 6. Couche staging
7. 7. Couche intermediate
8. 8. Règles de nettoyage et d'harmonisation
9. 9. Couche marts
10. 10. Exports CSV
11. 11. Contrôles de cohérence réalisés dans Snowflake
12. 12. Choix méthodologiques
13. 13. Prise en compte du RGPD
14. 14. Limites méthodologiques
15. 15. Conclusion du workflow

1. Objectif du workflow

L'objectif du workflow DBT est de préparer, transformer et fiabiliser les données internes OpenClassrooms afin de produire des tables finales exploitables pour l'analyse sociodémographique des étudiants inscrits aux parcours Data.

L'analyse porte sur l'évolution du profil des étudiants sur la période 2022–2025, selon trois dimensions principales :

- le genre;
- la tranche d'âge;
- la région.

Le workflow intègre également des données publiques issues de l'INSEE afin de contextualiser les résultats OpenClassrooms par rapport à la population française. Les données INSEE 2025 sont utilisées comme référentiel externe récent pour les comparaisons.


2. Environnement technique

- Snowflake : stockage des données sources et des tables/vues produites par DBT ;
- DBT : transformation, structuration et documentation du pipeline ;
- Power BI : restitution visuelle et exploration des indicateurs ;
- CSV : format d'export final des marts depuis Snowflake vers Power BI.

Les données brutes sont chargées dans Snowflake, puis déclarées comme sources dans DBT. Les modèles DBT sont ensuite exécutés afin de produire des tables analytiques finales dans le schéma de développement.

3. Organisation générale du pipeline DBT

Le pipeline est structuré en plusieurs couches logiques :



Cette organisation permet de séparer clairement la déclaration des sources, le nettoyage, la préparation intermédiaire et la production des tables finales d'analyse.

4. Sources de données

4.1 Données internes OpenClassrooms

Les données internes OpenClassrooms contiennent les informations nécessaires à l'analyse du profil sociodémographique des étudiants :

- année d'entrée dans le parcours ;
- genre ;
- âge ou tranche d'âge ;

- région ;
- volume d'étudiants.

Ces données couvrent la période 2022–2025.

4.2 Données INSEE

Les données INSEE sont utilisées pour contextualiser les résultats OpenClassrooms par rapport à la population française.

Dans ce projet, les données INSEE 2025 sont utilisées comme référentiel externe stable pour réaliser :

- une comparaison par genre;
- une comparaison par tranche d'âge;
- une comparaison par région.

5. Couche sources

Les sources sont déclarées dans un fichier YAML afin de documenter les tables brutes utilisées par DBT et de rendre les transformations reproductibles.

```
source_p8.yml
  → déclaration des tables sources OpenClassrooms et INSEE
```

6. Couche staging

La couche staging sert à nettoyer, renommer et standardiser les données brutes, sans produire encore les indicateurs finaux.

- harmoniser les noms de colonnes ;
- standardiser les valeurs de genre ;
- normaliser les régions ;
- préparer les tranches d'âge ;
- fiabiliser les formats numériques ;
- sélectionner uniquement les champs utiles à l'analyse.

```
stg_students.sql
stg_insee_population_region.sql
stg_insee_population_departement_genre_age.sql
```

7. Couche intermédiaire

La couche intermédiaire permet de préparer les données INSEE avant leur intégration dans les marts finaux.

```
int_insee_population_region_genre_age.sql
```

Le modèle intermédiaire permet de transformer les données INSEE initialement disponibles au niveau départemental en une base agrégée au niveau régional. Pour cela, les données de population par département sont jointes aux tables de correspondance COG départements et COG régions, afin d'associer chaque département à sa région. La population est ensuite agrégée par région, genre et tranche d'âge.

Cette étape est nécessaire car les données OpenClassrooms sont analysées au niveau régional. Elle permet donc d'obtenir une granularité commune entre les deux sources.

Étape	Objectif
INSEE département	Récupérer la population par département, genre et tranche d'âge
Jointure COG départements	Associer chaque département à un code région
Jointure COG régions	Récupérer le libellé de la région
Agrégation finale	Sommer la population par région, genre et tranche d'âge

8. Règles de nettoyage et d'harmonisation

8.1 Genre

Les valeurs de genre issues des données OpenClassrooms sont conservées pour l'analyse interne : F, M et Non renseigné. La catégorie Non renseigné est conservée dans l'analyse interne afin de mesurer la qualité des données.

Pour les comparaisons avec l'INSEE, seules les catégories comparables sont utilisées : femme et homme. La modalité Non renseigné est exclue des comparaisons INSEE car elle n'existe pas dans les données INSEE.

8.2 Tranches d'âge

Les tranches d'âge sont harmonisées afin d'assurer la comparabilité avec les données INSEE. Les catégories retenues sont :

- 20-39 ans ;
- 40-59 ans ;
- 60 ans ou plus.

8.3 Régions

Les régions sont standardisées afin de permettre les comparaisons entre les données OpenClassrooms et les données INSEE. Les territoires ultramarins sont regroupés sous la modalité DROM lorsque nécessaire, afin d'assurer une cohérence de niveau géographique.

9. Couche marts

Les marts correspondent aux tables finales d'analyse. Ils sont directement exploitables pour l'export CSV et la visualisation dans Power BI.

```
mart_sociodemo_global.sql
mart_evolution_genre.sql
mart_evolution_age.sql
mart_evolution_region.sql
mart_comparaison_region.sql
mart_comparaison_insee_region_genre_age.sql
```

9.1 Mart sociodémographique global

Le mart `mart_sociodemo_global` constitue la base principale de l'analyse interne OpenClassrooms. Il contient les agrégations par année, région, genre et tranche d'âge.

- évolution du nombre total d'étudiants ;
- répartition par genre ;
- répartition par tranche d'âge ;
- répartition régionale.

9.2 Mart de comparaison avec l'INSEE

Le mart `mart_comparaison_insee_region_genre_age` permet de comparer les données OpenClassrooms avec les données INSEE. Les comparaisons finales sont produites à partir des volumes afin de recalculer les parts selon le niveau d'analyse souhaité : genre, âge ou région.

10. Exports CSV

Les marts produits par DBT sont matérialisés dans Snowflake. Les fichiers CSV finaux sont obtenus en exécutant des requêtes SELECT sur les marts finaux puis en exportant les résultats depuis Snowflake.

Export Power BI	Origine Snowflake	Usage
<code>p8_sociodemo_global.csv</code>	<code>MART_SOCIODEMO_GLOBAL</code>	Analyse interne OpenClassrooms
<code>p8_sociodemo_clean.csv</code>	<code>MART_COMPARAISSON_INSEE_REGION_GENRE_AGE</code>	Comparaisons OpenClassrooms vs INSEE

11. Contrôles de cohérence réalisés dans Snowflake

Plusieurs contrôles ont été réalisés afin de vérifier la fiabilité des données transformées et la cohérence des indicateurs présentés dans Power BI.

11.1 Contrôle des volumes annuels

```
select
    year_path_started as year,
    sum(nb) as total_students
from JAUBRY_DBT.JOANA_DEV.MART_SOCIODEMO_GLOBAL
group by year_path_started
order by year_path_started;
```

Année	Nombre d'étudiants
2022	1696
2023	1150
2024	850
2025	951
Total	4647

11.2 Contrôle du total général

```
select
    sum(nb) as total_students
from JAUBRY_DBT.JOANA_DEV.MART_SOCIODEMO_GLOBAL;
```

Résultat attendu : 4647 étudiants.

11.3 Contrôles de la répartition par genre

11.3.1 Contrôle de la répartition globale par genre

```
select
  gender_clean,
  sum(nb) as nb_students,
  round(sum(nb) / sum(sum(nb)) over (), 4) as part_students
from JAUBRY_DBT.JOANA_DEV.MART_SOCIODEMO_GLOBAL
group by gender_clean
order by nb_students desc;
```

Ce contrôle permet d'identifier la répartition globale par genre et la part de la modalité Non renseigné.

11.3.2 Contrôle de la répartition par genre et par année

```
select
  year_path_started as year,
  gender_clean,
  sum(nb) as nb_students,
  round(
    sum(nb) / sum(sum(nb)) over (partition by year_path_started),
    4
  ) as part_year
from JAUBRY_DBT.JOANA_DEV.MART_SOCIODEMO_GLOBAL
group by
  year_path_started,
  gender_clean
order by
  year,
  gender_clean;
```

Ce contrôle valide le graphique d'évolution par genre dans Power BI. Le dénominateur est le total de l'année grâce au `partition by year_path_started`.

11.3.3 Validation de la somme des parts par année

```
with genre_year as (

  select
    year_path_started as year,
    gender_clean,
    sum(nb) as nb_students,
    sum(nb) / sum(sum(nb)) over (partition by year_path_started) as part_year
  from JAUBRY_DBT.JOANA_DEV.MART_SOCIODEMO_GLOBAL
  group by
    year_path_started,
    gender_clean

)

select
  year,
  round(sum(part_year), 4) as total_part_year
from genre_year
group by year
order by year;
```

Résultat attendu : 1.0000 pour chaque année. Ce contrôle confirme que les parts par genre se recomposent bien à 100 % par année.

11.4 Contrôle de la répartition par tranche d'âge

```
select
    year_path_started as year,
    age_group_insee,
    sum(nb) as nb_students,
    round(
        sum(nb) / sum(sum(nb)) over (partition by year_path_started),
        4
    ) as part_year
from JAUBRY_DBT.JOANA_DEV.MART_SOCIODEMO_GLOBAL
group by
    year_path_started,
    age_group_insee
order by
    year,
    age_group_insee;
```

11.5 Contrôle de la répartition régionale OC vs INSEE

```
with region_base as (

    select
        region,
        sum(nb_students) as nb_students,
        sum(population_insee_2025) as population_insee_2025
    from JAUBRY_DBT.JOANA_DEV.MART_COMPARAISSON_INSEE_REGION_GENRE_AGE
    where year = 2025
    group by region

),

parts as (

    select
        region,
        nb_students / sum(nb_students) over () as part_oc,
        population_insee_2025 / sum(population_insee_2025) over () as part_insee
    from region_base

)

select
    round(sum(part_oc), 4) as total_part_oc,
    round(sum(part_insee), 4) as total_part_insee
from parts;
```

Résultat attendu : total_part_oc = 1.0000 et total_part_insee = 1.0000. Ce contrôle permet de vérifier que les parts régionales se recomposent bien à 100 % pour OpenClassrooms et pour l'INSEE.

12. Choix méthodologiques

12.1 Utilisation de l'INSEE 2025

Les données INSEE 2025 sont utilisées comme référentiel externe récent. L'objectif n'est pas d'analyser l'évolution de la population française, mais de contextualiser le profil des étudiants OpenClassrooms par rapport à une structure démographique stable.

12.2 Traitement des valeurs Non renseigné

Les valeurs Non renseigné sont conservées dans l'analyse interne OpenClassrooms afin de mesurer la qualité des données et son évolution dans le temps. Cette modalité représente une part importante sur l'ensemble de la période, mais elle diminue fortement pour atteindre environ 6,7 % en 2025.

Pour les comparaisons avec l'INSEE, l'analyse est réalisée sur les genres renseignés uniquement, c'est-à-dire femme et homme, car l'INSEE ne dispose pas d'une modalité équivalente à Non renseigné. Ce choix permet de comparer les données OpenClassrooms et INSEE sur une base commune, tout en mentionnant cette limite méthodologique.

12.3 Harmonisation des tranches d'âge

Les tranches d'âge OpenClassrooms ont été harmonisées selon les tranches disponibles dans les données INSEE afin de garantir une granularité commune entre les deux sources. Les catégories retenues pour l'analyse sont : 20–39 ans, 40–59 ans et 60 ans ou plus.

Ce choix permet de comparer les distributions d'âge OpenClassrooms et INSEE sur une base cohérente, même si certaines tranches initiales ont dû être regroupées.

13. Prise en compte du RGPD

Les restitutions finales sont réalisées uniquement à partir de données agrégées. Aucun identifiant individuel n'est présenté dans les visualisations ou dans le support de présentation.

Les analyses sont produites à un niveau statistique : année, genre, tranche d'âge et région. Cette approche permet de répondre à l'objectif d'analyse tout en limitant les risques liés à l'exposition de données personnelles.

14. Limites méthodologiques

- Les données INSEE utilisées correspondent à l'année 2025 uniquement ;
- La population INSEE représente la population générale, et non spécifiquement la population en formation ou en reconversion ;
- La catégorie Non renseigné est présente dans les données OpenClassrooms, notamment sur les premières années ;
- Certaines comparaisons doivent être interprétées comme des éléments de contextualisation et non comme des équivalences strictes.

15. Conclusion du workflow

Le workflow DBT permet de transformer les données brutes en tables analytiques structurées, documentées et reproductibles.

Les contrôles réalisés dans Snowflake confirment la cohérence des volumes et des indicateurs produits. Les exports CSV issus des marts DBT alimentent ensuite Power BI pour la restitution des analyses et la préparation du support de présentation.