

PROJET 12

Détection automatique de faux billets

Comparaison de modèles, sélection et mise en production

Joana Aubry

OpenClassrooms · Data Analyst · Juillet 2026

Contexte et objectif métier

De la mesure géométrique à une décision automatique

Contexte

L'ONCFM souhaite automatiser l'identification des faux billets à partir de mesures physiques simples.

Objectif

Construire, comparer et déployer un modèle capable de classer un billet comme authentique ou faux.

Erreur critique

Un faux billet classé comme authentique est l'erreur la plus sensible pour le dispositif de contrôle.

1 500

billets disponibles

6

caractéristiques géométriques

5

modèles comparés

1


script de production

Question directrice

Quel modèle offre le meilleur compromis entre détection des faux billets, stabilité et interprétabilité ?

Les données disponibles

Un jeu de données tabulaire, équilibré pour une classification binaire



1 000 vrais billets · 500 faux billets

VARIABLES MESURÉES

● diagonal	diagonale
● height_left	hauteur gauche
● height_right	hauteur droite
● margin_low	marge inférieure
● margin_up	marge supérieure
● length	longueur

Cible : is_genuine True = authentique · False = faux

Qualité des données et préparation


Préparer sans fuite d'information



Le jeu de test reste isolé jusqu'à l'évaluation finale des modèles.

Analyse exploratoire des données

Quelles variables sont les plus liées à la nature du billet ?



PRINCIPAUX CONSTATS

Lecture de la cible : Faux = 0 · Authentique = 1


- length présente la corrélation positive la plus forte avec la cible : **+0,85**.
- margin_low (**-0,78**) et margin_up (**-0,61**) sont fortement associées aux faux billets.
- height_right et height_left contribuent également à la distinction, mais de manière plus modérée.
- diagonal est faiblement corrélée à la cible : **+0,13**.

La longueur et les marges apparaissent comme les variables les plus discriminantes

Une corrélation mesure une association statistique, et non une relation de causalité.

Ce que révèle l'analyse exploratoire

La longueur et la marge inférieure séparent déjà fortement les billets



PRINCIPAUX CONSTATS

Chaque point représente un billet.
Le graphique croise les deux variables les plus discriminantes observées lors de l'analyse exploratoire : **la longueur** et **la marge inférieure**.
Les billets authentiques sont en **bleu** et les faux billets en **orange**.

- Les billets authentiques sont globalement plus longs.
- Les faux billets présentent généralement une marge inférieure plus élevée.
- Quelques zones de chevauchement subsistent, ce qui justifie l'utilisation d'un modèle multivarié intégrant les six mesures.

Une séparation déjà nette, mais quelques chevauchements justifient une approche multivariée.

Démarche de modélisation

Quatre modèles demandés + un modèle complémentaire

APPRENTISSAGE SUPERVISÉ

Régression
logistique

KNN

Random
Forest

SVM

APPRENTISSAGE NON SUPERVISÉ

K-means

clusters ensuite associés
aux classes réelles

CRITÈRES DE COMPARAISON

Accuracy

performance globale

Précision

fiabilité des alertes faux

Rappel

part des faux détectés

F1-score

équilibre précision / rappel


FN

faux billets non détectés

Validation et optimisation

Comparer les modèles dans des conditions identiques

VALIDATION CROISÉE



5 plis stratifiés

Chaque observation sert à l'entraînement et à la validation, sans toucher au jeu de test.

OPTIMISATION

- GridSearchCV pour KNN, Random Forest et SVM
- Score de sélection : F1 des faux billets
- Hyperparamètres choisis uniquement sur le jeu d'entraînement
- Meilleur estimateur réentraîné automatiquement

JEU DE TEST


300

billets jamais vus

- 200 authentiques
- 100 faux
- Évaluation finale après choix des hyperparamètres

Comparaison des performances

Des résultats très élevés et très proches




LECTURE

- Régression logistique et Random Forest en tête.
- K-means atteint aussi 98 % de rappel.
- KNN et SVM détectent 97 % des faux billets.
- Les écarts sont faibles : le choix final doit aussi intégrer simplicité et stabilité.

Erreur métier prioritaire

Combien de faux billets sont classés comme authentiques ?



2

faux billets non détectés

Régression logistique
Random Forest
K-means

Le graphique ne suffit pas seul : il faut aussi considérer les autres erreurs et l'interprétabilité.

Pourquoi retenir la régression logistique ?

Le meilleur compromis, pas uniquement le meilleur score

99,0 %

accuracy sur le jeu de test

98,0 %

rappel des faux billets

98,5 %

F1-score des faux billets

2

faux billets non détectés

0,989

F1 moyen en CV

Performance

Égalité avec le Random Forest sur le test.

Stabilité

F1 moyen légèrement supérieur en validation croisée.

Simplicité

Modèle rapide à entraîner, déployer et expliquer.


Interprétabilité

Les coefficients permettent d'identifier le rôle des variables.

Modèle final retenu : régression logistique

Performance du modèle final

297 billets correctement classés sur 300



INTERPRÉTATION

98

faux détectés

2

faux non détectés

199

vrais reconnus


1

vrai rejeté

Le risque résiduel principal concerne les deux faux billets classés comme authentiques.

Interprétation des variables

Comprendre la décision du modèle final



VARIABLES CLÉS

length +3,739

Une longueur plus élevée favorise la classe authentique.

margin_low -2,684

Une marge inférieure plus élevée est associée aux faux billets.

margin_up -1,632

La marge supérieure contribue aussi fortement à la détection.

Les coefficients décrivent des associations statistiques, pas des relations causales.

Passage en production

Du notebook à un outil réutilisable



Mode fichier CSV Prédiction de toutes les lignes du fichier

Mode billet unique Saisie directe des six dimensions

Test du script sur le fichier de production

Le fichier d'exemple contient 5 nouveaux billets

```
PROBLEMS OUTPUT DEBUG CONSOLE TERMINAL PORTS JUPYTER
PS C:\Users\Joana Aubry\AppData\Local\Programs\Microsoft VS Code> & C:\Python312\python.exe "c:/Users/Joana Aubry/Documents/DATA ANALYST COURS TRAINING/Projets/Projet_12/Notebook/prediction_billets.py"
Modèle chargé avec succès.

Résultats des prédictions :
id is_genuine
A_1 False
A_2 False
A_3 False
A_4 True
A_5 True

Résumé :
Faux billets : 3
Billets authentiques : 2
PS C:\Users\Joana Aubry\AppData\Local\Programs\Microsoft VS Code>
```

RÉSULTAT

5

billets analysés

3

prédits faux

2

prédits authentiques

Aucune métrique n'est calculable sans classes réelles.

Conclusion

Un modèle performant, interprétable et opérationnel

Résultat

La régression logistique atteint 99 % d'accuracy et détecte 98 % des faux billets.

Décision

Elle est retenue pour son équilibre entre performance, stabilité, simplicité et explicabilité.

Déploiement

Le pipeline est sauvegardé et utilisable via un script autonome sur de nouveaux billets.

PISTES D'AMÉLIORATION

- Ajuster le seuil de décision pour privilégier encore davantage le rappel des faux billets.
- Tester des méthodes de boosting et mesurer le gain réel par validation croisée.
- Suivre les performances sur de nouvelles données réelles et réentraîner le modèle si nécessaire.

Merci pour votre attention

Annexe — Synthèse des modèles testés

Principe de fonctionnement, configuration retenue et résultat de validation

Prétraitement commun : imputation des valeurs manquantes par la médiane. La standardisation est appliquée lorsque nécessaire.

Modèle	Type	Principe simplifié	Configuration retenue	Validation
Régression logistique	Supervisé	Estime une probabilité à partir d'une frontière linéaire	Variables standardisées	F1 moyen des faux billets en validation croisée : 0,989
KNN	Supervisé	Classe selon le vote des voisins les plus proches	7 voisins	F1 moyen des faux billets en validation croisée : 0,987
Random Forest	Supervisé	Combine les décisions de plusieurs arbres	100 arbres · au moins 2 observations par feuille	F1 moyen des faux billets en validation croisée : 0,987
K-means	Non supervisé	Regroupe les billets en deux clusters	2 groupes · 20 initialisations	ARI : 0,940 · silhouette : 0,344
SVM	Supervisé	Recherche la frontière séparant au mieux les classes	Frontière linéaire · forte pénalisation des erreurs (C = 100)	F1 moyen des faux billets en validation croisée : 0,989

Le SVM a été ajouté comme modèle complémentaire. Le K-means étant non supervisé, ses indicateurs ARI et silhouette ne sont pas directement comparables au F1-score des modèles supervisés.

Annexe — Questions méthodologiques

Réponses courtes sur les choix de préparation et d'évaluation

Question	Réponse courte pour la soutenance
Pourquoi privilégier la détection des faux billets ?	L'erreur la plus sensible est de classer un faux billet comme authentique. Le rappel des faux billets est donc prioritaire.
Pourquoi utiliser le F1-score ?	Il combine la précision et le rappel. Il permet d'évaluer la détection des faux billets sans ignorer les fausses alertes.
Comment la régression logistique produit-elle une classe ?	Elle estime une probabilité pour chaque classe. Avec un seuil de 0,5, le billet est classé comme authentique ou faux. Les classes obtenues à partir des probabilités correspondent aux prédictions du modèle.
Pourquoi imputer avec la médiane ?	La médiane est moins sensible aux valeurs extrêmes et à l'asymétrie que la moyenne. Elle est apprise uniquement sur les données d'entraînement.
Pourquoi standardiser les variables ?	La standardisation évite qu'une variable influence davantage le modèle uniquement à cause de son échelle. Elle est essentielle pour le KNN, le SVM et le K-means.
Comment éviter la fuite de données ?	L'imputation et la standardisation sont intégrées dans les pipelines et apprises uniquement sur les données d'entraînement.

Idée clé : les traitements sont appris sur l'entraînement, puis appliqués au test et aux nouveaux billets.

Annexe — Sélection et mise en production


Réponses courtes sur le modèle final, le K-means et le script

Question	Réponse courte pour la soutenance
Pourquoi retenir la régression logistique plutôt que le Random Forest ?	Les deux modèles obtiennent les mêmes résultats sur le test, mais la régression logistique est plus simple, plus interprétable et légèrement meilleure en validation croisée.
Pourquoi une matrice de confusion pour le K-means ?	Après avoir associé chaque cluster à sa classe majoritaire, elle permet de comparer les groupes obtenus aux classes réelles. ARI et silhouette complètent l'évaluation.
Pourquoi entraîner le modèle final sur les 1 500 billets ?	Le jeu de test a déjà servi à l'évaluation objective. Pour la production, on exploite ensuite toutes les données connues.
Pourquoi ne pas calculer de métriques sur le fichier de production ?	Ce fichier ne contient pas les classes réelles. Il est donc possible de produire des prédictions, mais pas d'évaluer leur exactitude.
Le script est-il limité à cinq billets ?	Non. Il traite automatiquement toutes les lignes du CSV. Le fichier d'exemple fourni contient simplement cinq billets.

Idée clé : le notebook construit et sauvegarde le modèle ; le script charge ce modèle pour prédire de nouveaux billets.

Annexe — Complément à l'analyse exploratoire

La longueur et la marge inférieure séparent déjà fortement les billets



PRINCIPAUX CONSTATS

Ce pairplot permet d'observer simultanément la distribution de chaque variable et les relations entre toutes les paires de variables, en distinguant les billets authentiques et les faux billets.

On constate que la longueur et la marge inférieure sont les variables les plus discriminantes.

La marge supérieure et les hauteurs apportent également de l'information, tandis que la diagonale présente un fort chevauchement entre les deux classes.